Université Cadi Ayyad Marrakech
Ecole Supérieure de Technologie Essaouira
LP ISIL Semestre 6

Module 8

Bases de Données Avancées

Chapitre II

BUSINESS INTELLIGENCE
CONCEPTION DE DATA WAREHOUSE

Pr: A. Guezzaz

Année: 2019 -2020

I. Introduction au Business Intelligence (BI)

1. Introduction à l'aide de décision
2. Transactionnel vers Décisionnel
3. Entrepôts de données (DW)
4. Cycle de vie d'un projet BI

II. Conception d'un entrepôt de données (DW)

1. Analyse de l'entrepôt de données
2. Modélisation de l'entrepôt de données
   - Modèle en Étoile (Star Schema)
   - Modèle en Flocons de neige (Snowflack Schrma)
   - Modèle Mixte (Mixed Shema)
   - Modèle en Constellation (Fact Constellation Schema)
3. Evolution des dimensions

Introduction au Business Intelligence (BI)

Introduction à l'aide de décision

- Décider des actions à conduire,
- Contrôle l'exécution des travaux,
- Analyse l'environnement,
- Contrôle le système opérant,

  - Collecter,
  - Mémoriser,
  - Traiter,
  - Distribuer l'information.

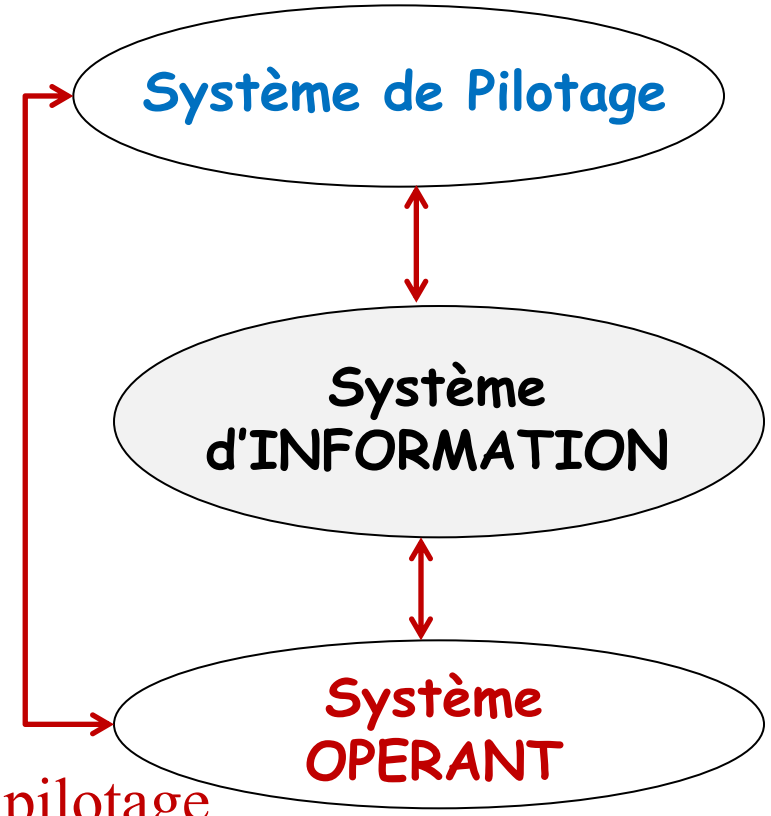

- Fabriquer les produits
- Facturer les clients,. …
- Exécutent les ordres du système de pilotage

Quels outils donner au décideur pour comprendre, piloter et gérer ?

Introduction à l'aide de décision

❑Besoin

Améliorer les performances décisionnelles de l'entreprise:

- Décisions **stratégiques,**
- Décisions **rapides.**

❑Pourquoi ?

Besoin de réactivité face à la concurrence.

❑Qui ?

Les décideurs (non informaticiens).

❑Comment ?

En répondant aux demandes d'analyse.

Transactionnel vers Décisionnel

❑ Caractéristiques du Transactionnel

- « Le **système transactionnel** est généralement une base de données, développée par application, stockant les **données courantes** d'une organisation. **Il n'y a pas de données d'archives** dans les systèmes transactionnels».

- **Opérations d'un système transactionnel:**
  - *Ajout;*
  - *Suppression;*
  - *Mise à jour des enregistrements;*
  - *Requêtes simples, ……*

Transactionnel vers Décisionnel

❑ Contraintes du Transactionnel

- Nombre élevé de tables donc **nombre élevé de jointures**.
- Élaboration complexe des requêtes.
- Temps de traitement long.

- Les **processus de décision** nécessitent :
  - **Données agrégées (résumées)** provenant de différentes BD dispersées et intégrées.
  - **Données historiques (historisées).**
  - **Réponses rapides** (requêtes surtout de type **agrégatif**).
  - **Interfaces** faciles à utiliser par l'utlisateur.

Transactionnel vers Décisionnel

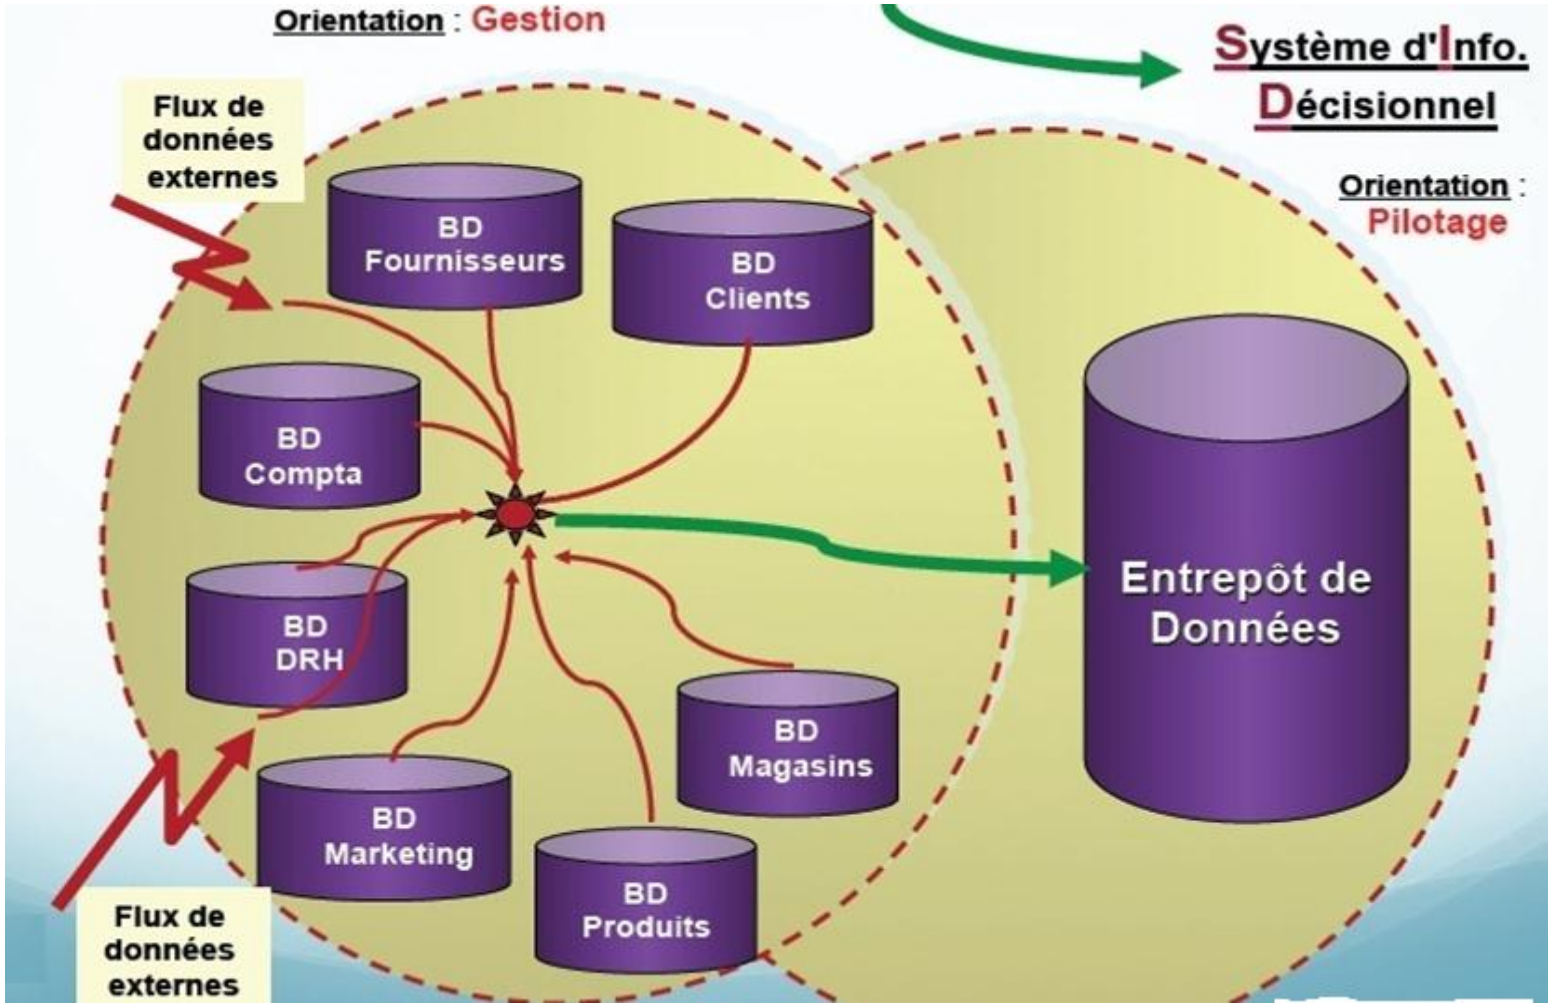

Entrepôts de données (DW)

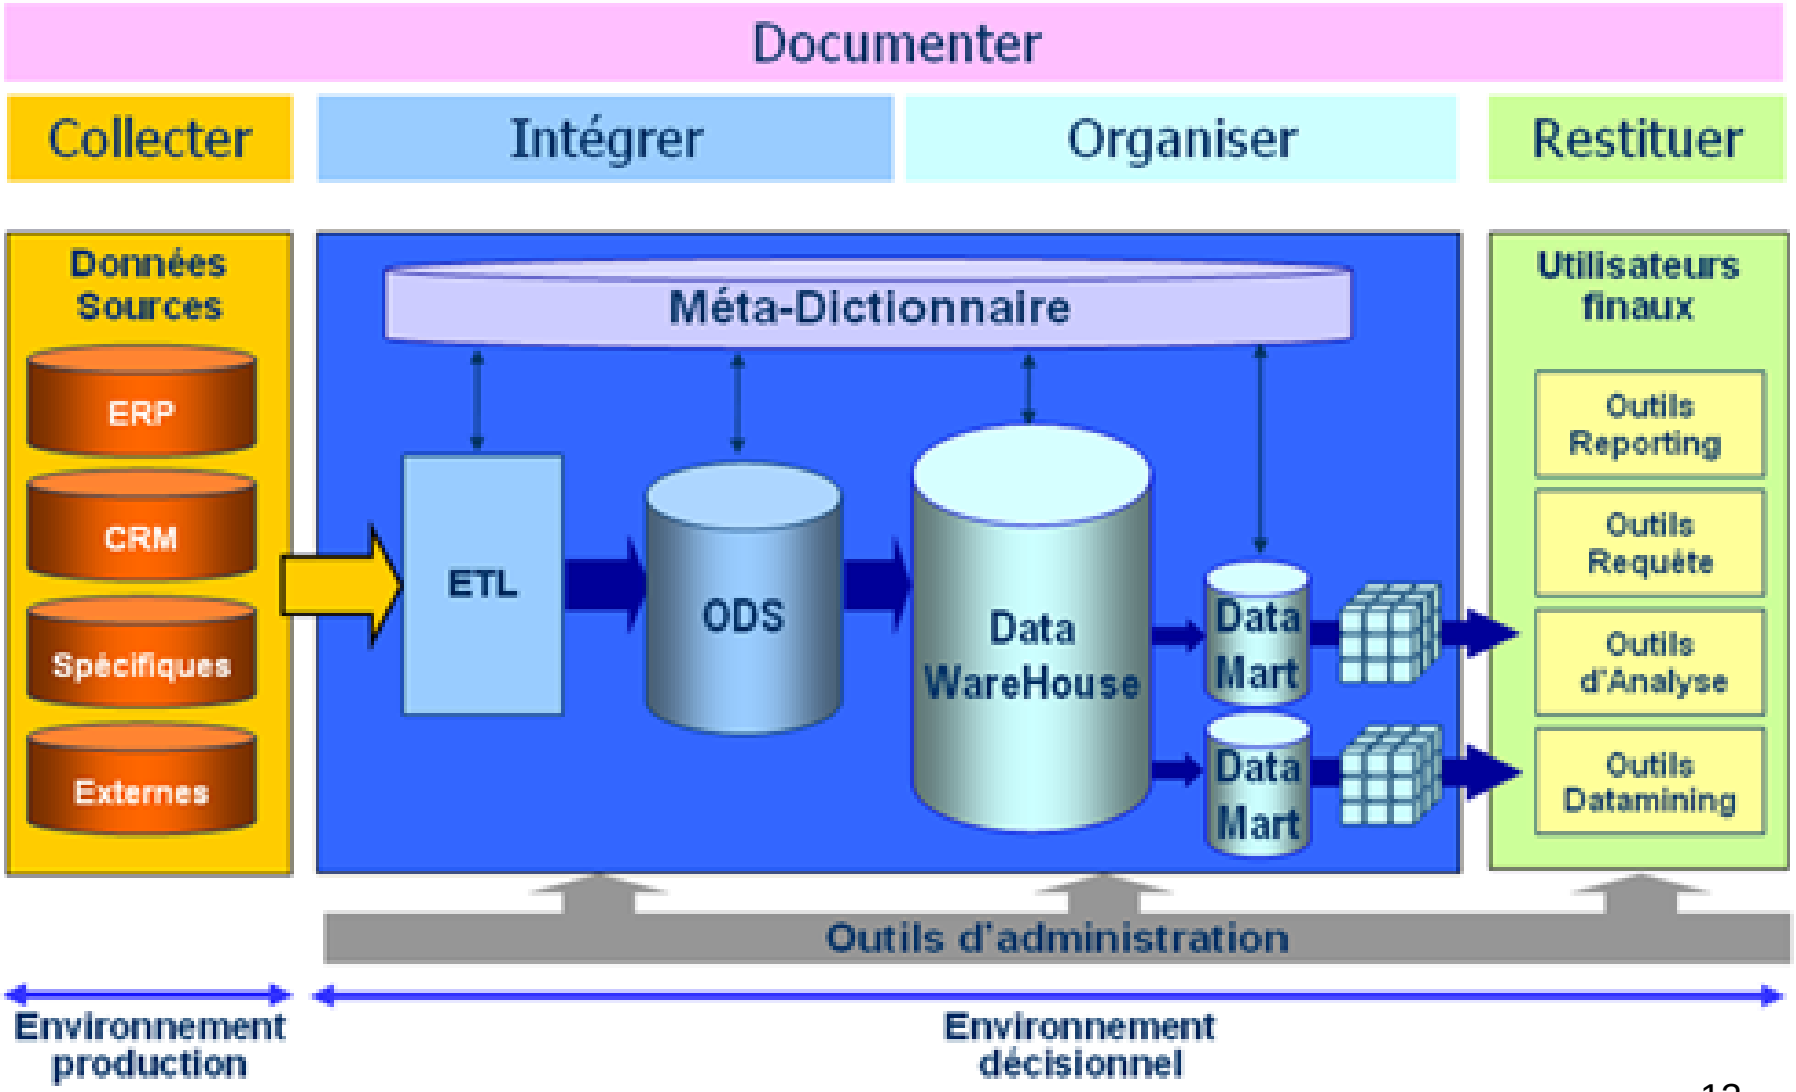

Entrepôts de données (DW)

❑ Data Marts (DM)

- **Data Marts: sous-ensembles d'un entrepôt de données** destinés à répondre **aux besoins** d'un secteur ou d'une fonction **particulière ou d'un utilisateur particulier**.
- **Moins** de données que DW et **plus facile** à comprendre et à manipuler.
- **Amélioration** des **temps de réponse**.
- Utilisateurs plus **ciblés**: DM plus facile à définir.

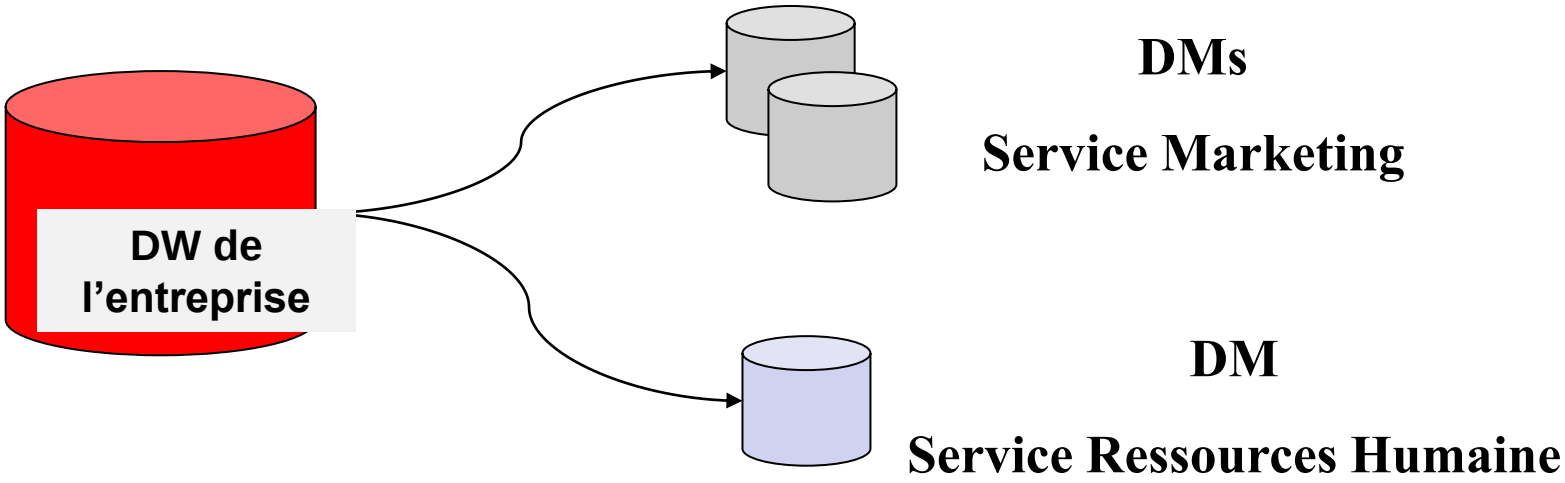

Cycle de vie d'un projet BI

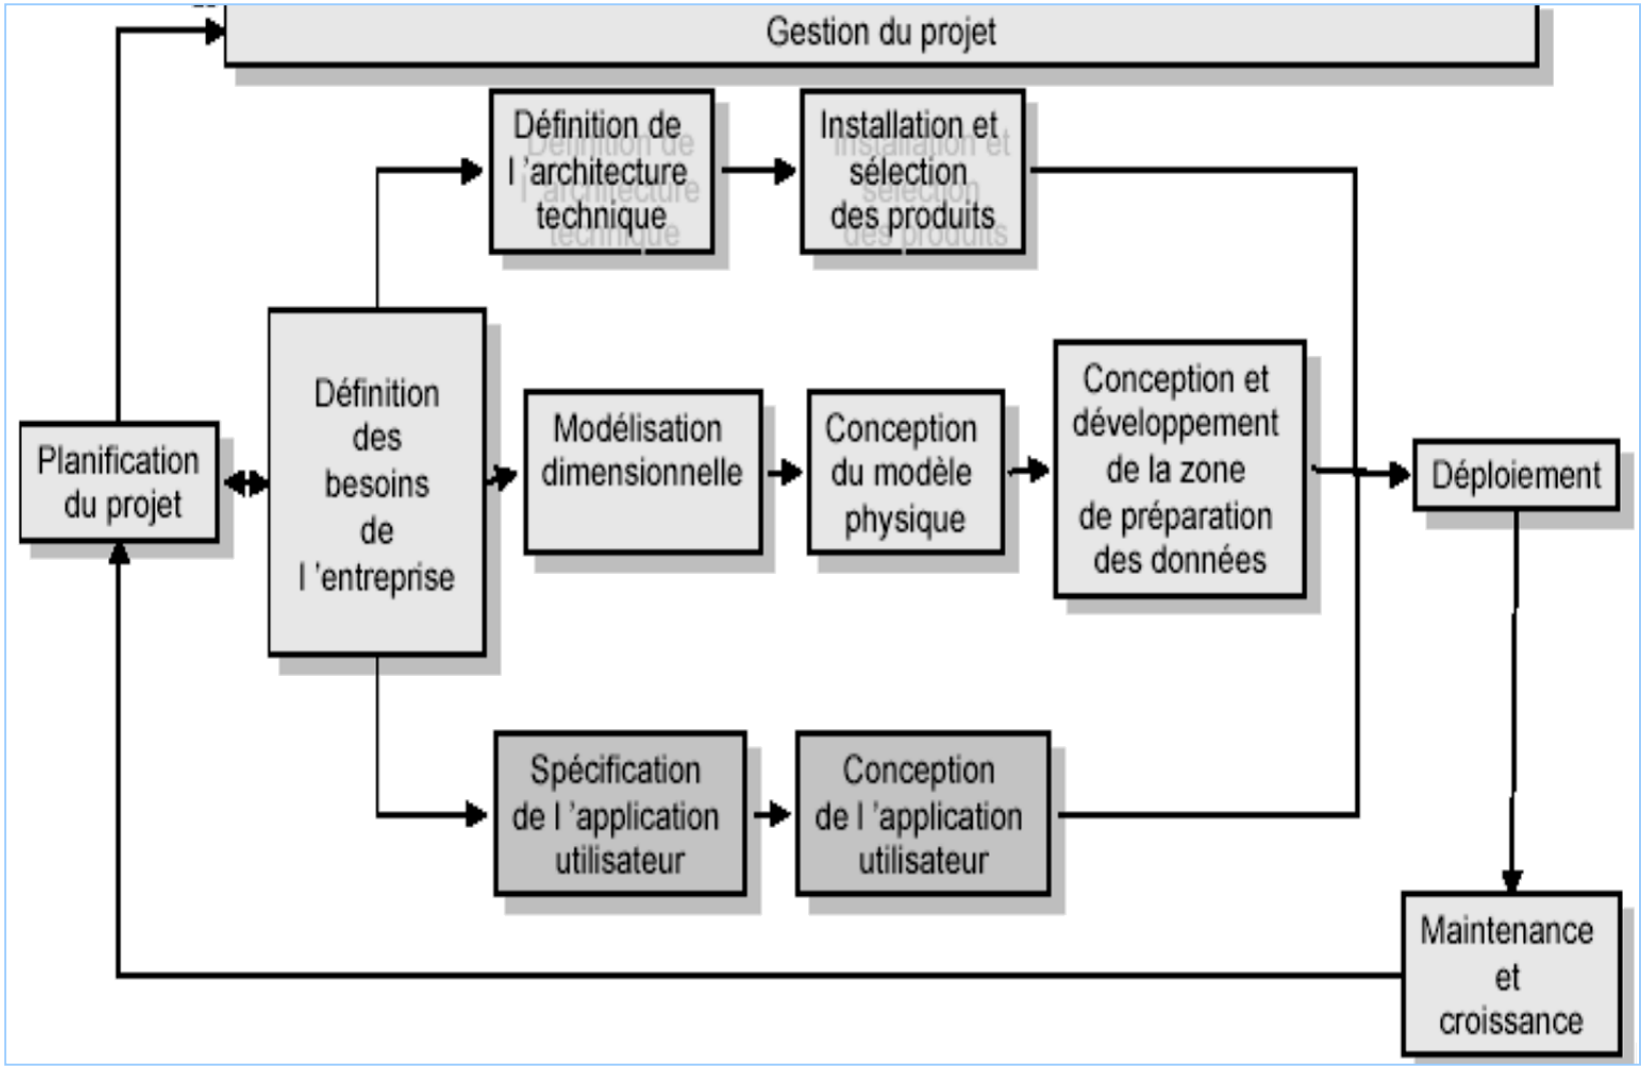

Cycle de vie d'un projet BI

❑ Planification du projet

- La **planification** aborde la définition et l'extension du projet BI.
- Elle se concentre **sur les besoins** en terme de **ressources** et de **niveau de qualification**, couplés aux affectations **des tâches**, à **leur durées** et à **leur séquencement. La planification dépend bien évidemment des besoins.**

❑ Description des besoins

- Il est essentiel de bien comprendre **les utilisateurs et leurs besoins,** sinon l'entrepôt devient simplement un exercice de la part des concepteurs.

Cycle de vie d’un projet BI

❑ Définition des besoins de l’entreprise

- **Etude** du **domaine métier**: pour connaître le **métier de l'entreprise,** se familiariser avec les termes utilisés et découvrir les informations cachées et avec les différents logiciels utilisés dans l'entreprise.
- **Interview** des acteurs clés du métier (connaître **l'organigramme** de l'entreprise et savoir **qui s'occupe de quoi**).
- **Découpage** des **besoins** en **sujets**: A partir des synthèses établies après interview. Il faut classer les besoins en sujets d'analyse.

Cycle de vie d'un projet BI

❑ Modélisation dimensionnelle

- C'est la **définition des besoins** qui détermine quelles sont les données requises pour répondre aux besoins d'analyse des utilisateurs.

  - **Le résultat de cette analyse est le modèle dimensionnel.**

❑ Modèle physique

- Définition des **structures** nécessaires pour **l'implémentation physique** du **modèle dimensionnel** (Environnement de la BD).

  - **La conception du modèle physique est fortement dépendante du système utilisé pour l'entrepôt.**

Cycle de vie d'un projet BI

❑ Préparation des données

- La conception de la **zone de préparation** (staging area) est une tâche importante dans un projet BI qui se déroule en **trois phases** majeures :

  1. **Extraction,**
  2. **Transformation,**
  3. **Chargement.**

❑ Architecture technique

- **L'architecture technique** nécessite la **prise en compte des besoins** de l'environnement: plateformes **matérielles et logicielles**

  ✓ **SGBD,**

  ✓ **Outils d'extraction,**

  ✓ **Outils de restitution.**

Cycle de vie d'un projet BI

❑ Applications des utilisateurs

- Définition d'une série d'applications standard destinées aux utilisateurs finaux (maquettes, les états, etc…).

❑ Déploiement

- Une **planification est indispensable** pour gérer le déploiement:
  - ❖ la formation des utilisateurs,
  - ❖ le support utilisateur,
  - ❖ la prise en compte des demandes d'évolution et de correction.

Cycle de vie d'un projet BI

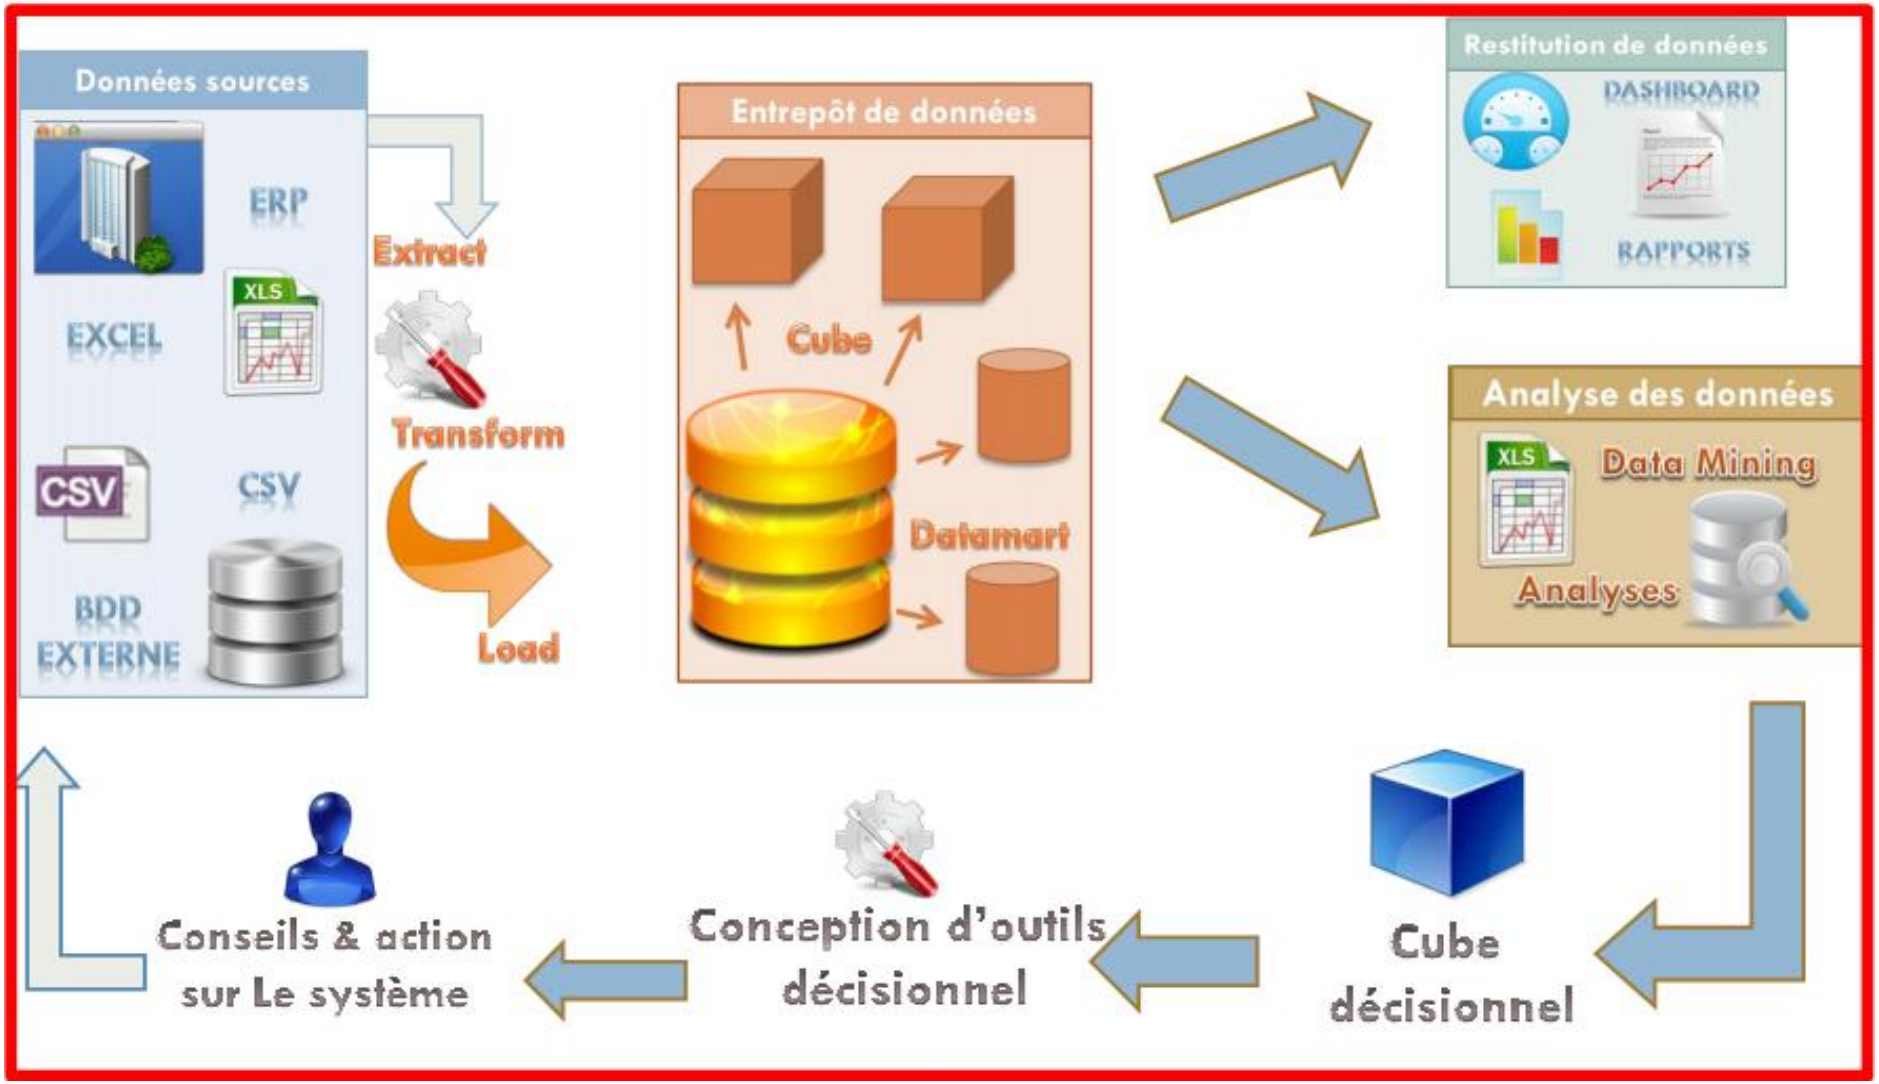

Conception d’un entrepôt de données (DW)

Analyse de l'entrepôt de données

❑ Flux entrant

- **Extraction**: multi-source, hétérogène,
- **Transformation**: filtrer, trier, homogénéiser, nettoyer,
- **Chargement**: insertion des données dans l'entrepôt.

❑ Flux sortant:

- **Mise à disposition** des données pour les utilisateurs finaux (**Restitution**).

❑ Zone de préparation

- **Zone temporaire** de stockage des données **extraites** pour faire le **nettoyage**, la **normalisation** et **d'autres transformations**.
- Données souvent **détruites** après chargement dans le DW.

Analyse de l'entrepôt de données

❑ Zone de stockage (DW)

- On y **transfère** les données **nettoyées.**
- **Stockage permanent** des données.

❑ Zone de présentation

- **Accès** aux données contenues dans **DW**, elle peut contenir des **outils d'analyse** programmés: **Rapports, Requêtes…**

Analyse de l'entrepôt de données

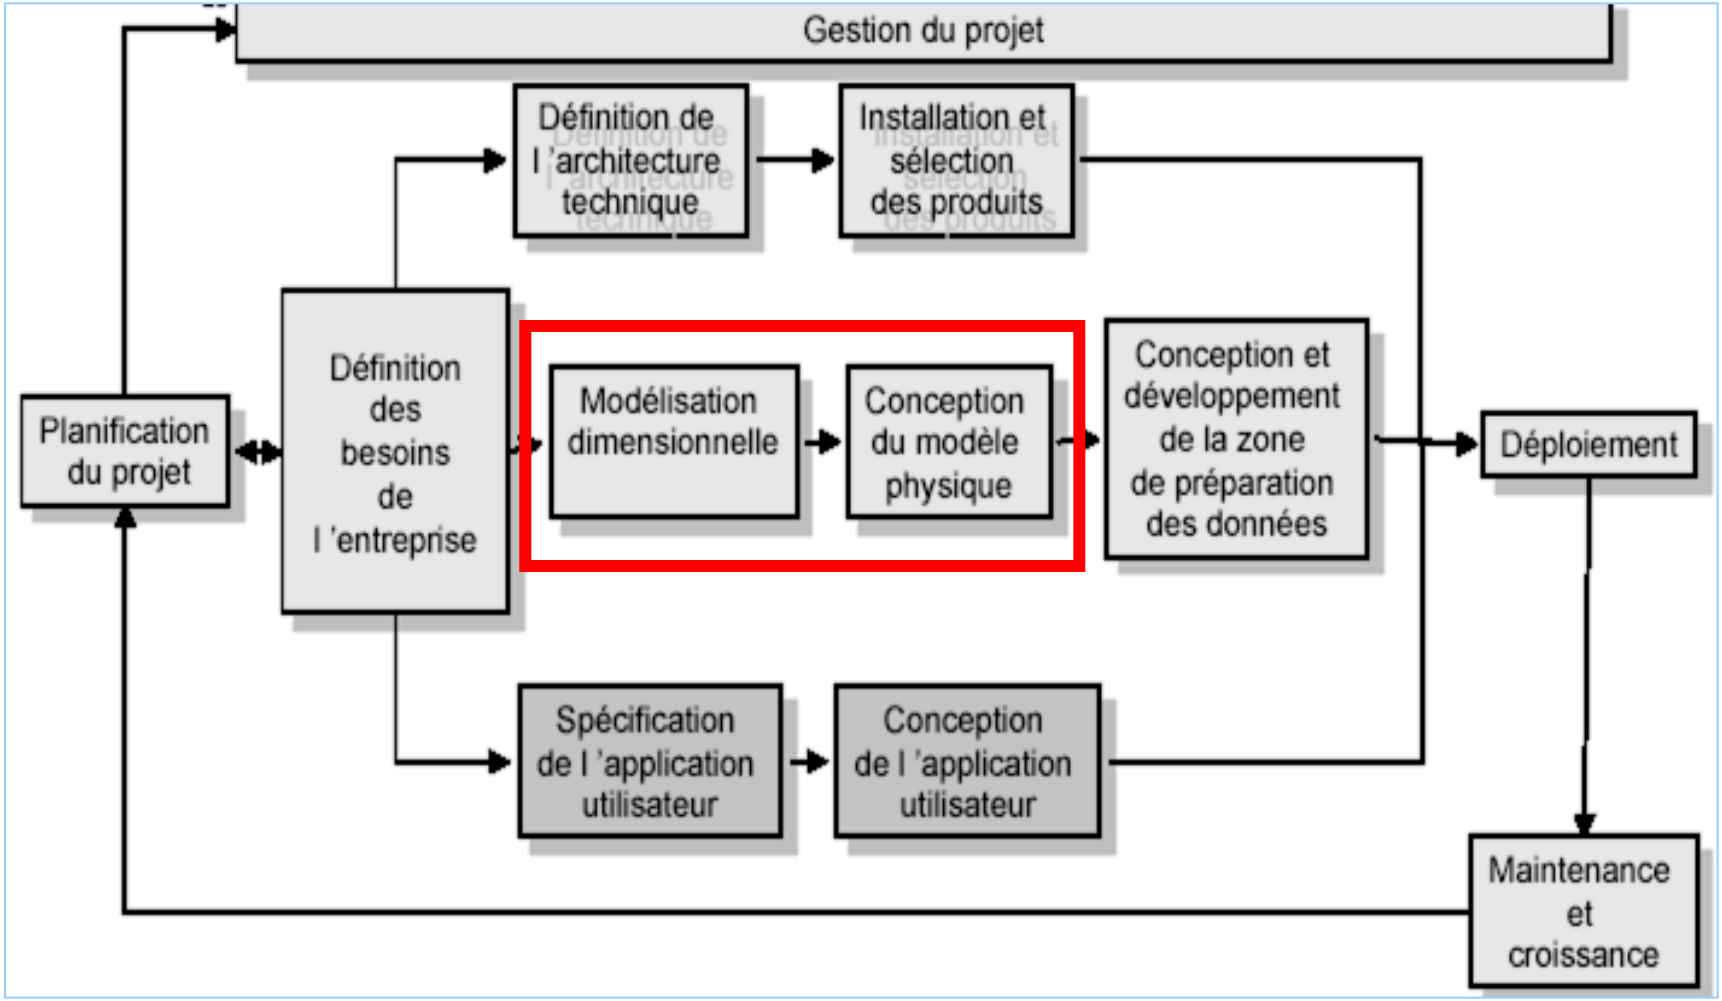

Analyse de l’entrepôt de données

- Le **but** est de déterminer
  - Les **dimensions**: ou les axes d'analyses avec leurs attributs.
  - Les **faits**: ou les éléments à analyser.

- **l'étude approfondie** de ce qui se passe dans l'entreprise
  - Documents échangés, rapports périodiques, interviews des personnes clés, étude des besoins.

- Faire **un travail d'acteur** et détailler chaque utilisateur
  - Savoir comment les analystes organisent leurs raisonnements.
  - Savoir ce que voient les décideurs avant de décider.

Analyse de l'entrepôt de données

❑ Table de Fait

- Un fait est la plus petite information analysable.
- La table de fait contient les données observables **(faits)** sur un sujet qu'on veut étudier, selon divers axes d'analyse **(dimensions).**
- Ce qu'on souhaite mesurer: quantités vendues, montant des ventes…
- Trois types de faits:
  - ❖Additif.
  - ❖Semi additif.
  - ❖Non additif.

Analyse de l'entrepôt de données

❑ Table de Fait

- **Additif**: additionnable suivant toutes les dimensions.
  - Quantités vendues, chiffre d'affaire.
  - Peut être le résultat d'un calcul: *Bénéfice = montant vente – coût*
- **Semi additif**: additionnable suivant certaines dimensions.
  - *Solde d'un compte bancaire*:
    - ➢Pas de sens d'additionner sur les dates.
    - ➢Sommation des comptes: on connaît ce qu'on possède en banque.
- **Non additif**: fait non additionnable quelque soit la dimension.
  - *Prix unitaire*: l'addition sur n'importe quelle dimension donne la même valeur.

❑ Table de Fait

- Table principale du modèle dimensionnel.

	Table de faits des ventes
Clés étrangères vers les dimensions	Clé date (CE)
	Clé produit (CE)
	Clé magasin (CE)
Faits	**Mesure1:** Quantité vendue
	Mesure2: Coût
	Mesure3: Montant des ventes

Analyse de l'entrepôt de données

❑ Table de Fait

- **Mesures**: valeurs numériques des mesures désirées.
- **Clés étrangères**: clés associées aux dimensions.
- Une table de faits contient un **petit nombre** de colonnes et **plus d'enregistrements** qu'une table de dimension.
- Les informations dans une table de faits sont **numériques** et utilisées pour faire des **SUM, AVG...** et doivent être **additives** ou **semi additives.**
- Les mesures **doivent référer** et **avoir un lien direct** avec les **clés des dimensions** dans la même table.

Analyse de l'entrepôt de données

❑ Table de Fait

- La **granularité** répond à la question :
  - Que *représente un enregistrement* de la table de faits ?
- La **granularité** définit le **niveau de détails** de la table de faits:

Exemple:

- Une ligne de commande par produit, par client et par jour

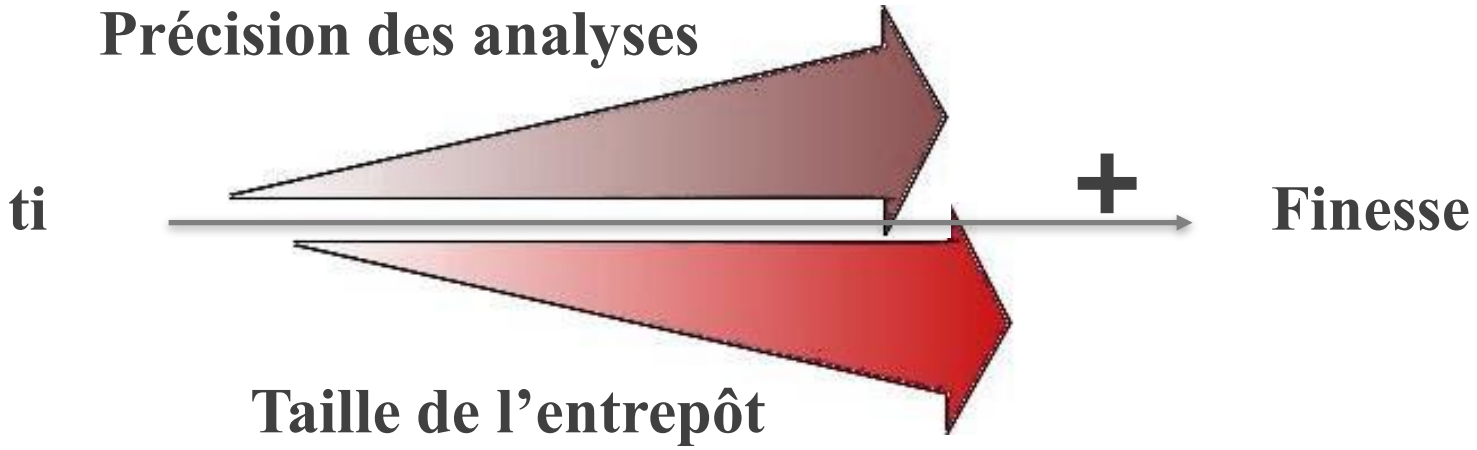

Analyse de l'entrepôt de données

❑ Table de dimension

- Une **dimension** est une table qui représente un **axe d'analyse** selon lequel on veut étudier **les faits** qui donnent des renseignements nécessaires à la prise de décision.
- Il s'agit des clients ou des produits d'une entreprise et du temps.

Clé de substitution (**Surrogate Clef**)

Attributs de la dimension

Dimension produit
Clé produit (PK)
Code produit
Description du produit
Famille du produits
Marque
Poids

Analyse de l'entrepôt de données

❑ Table de dimension

- **Dimension = axe d'analyse**
  - ➢Client, produit, période de temps…
- Contient souvent un grand nombre de colonnes
  - ➢L'ensemble des informations descriptives des faits.
- Contient en général moins d'enregistrements qu'une table de faits

❖ **Composant 1** : clé de substitution (Surrogate key).

❖ **Composante 2** : Atributs.

❖ **Composante 3** : Clés spéciales.

Analyse de l'entrepôt de données

Table de dimension

- **Exemple:**

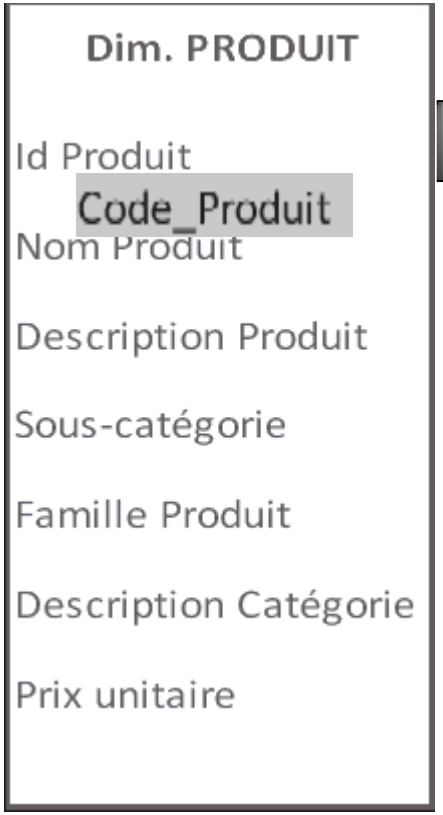

Surrogate key
(clé de substitution)

Clé Naturelle
(clé artificielle)

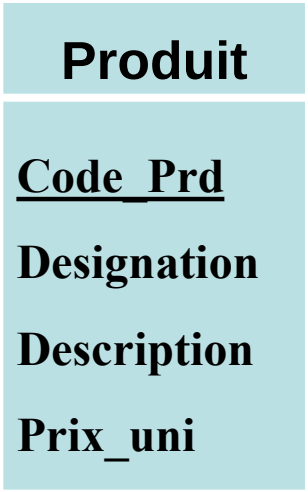

Table d'une BD de production

Table d'une BD multidimensionnelle

Analyse de l'entrepôt de données

❑ Table de dimension

- **Remplacer la clé naturelle en utilisation**: ce n'est pas elle qui est utilisée pour les jointures avec les tables de faits et de dimension.
- **Compléter l'information :** la clé de substitution est utilisée dans le DW seulement, la clé artificielle dans la dimension est **toujours nécessaire** pour pouvoir faire la correspondance entre la dimension et la table opérationnelle.
- **Historique des changements:** pour garder l'historique des changements de la dimension selon certains critères, **on doit gérer la clé de substitution**.

Analyse de l'entrepôt de données

❑ Table de dimension

- En plus de la clé de substitution ou naturelle, d'autres attributs sont ajoutés à la dimension.
- Ces attributs sont des descripteurs qui représentent l'information utile sur la dimension, généralement de type caractère.

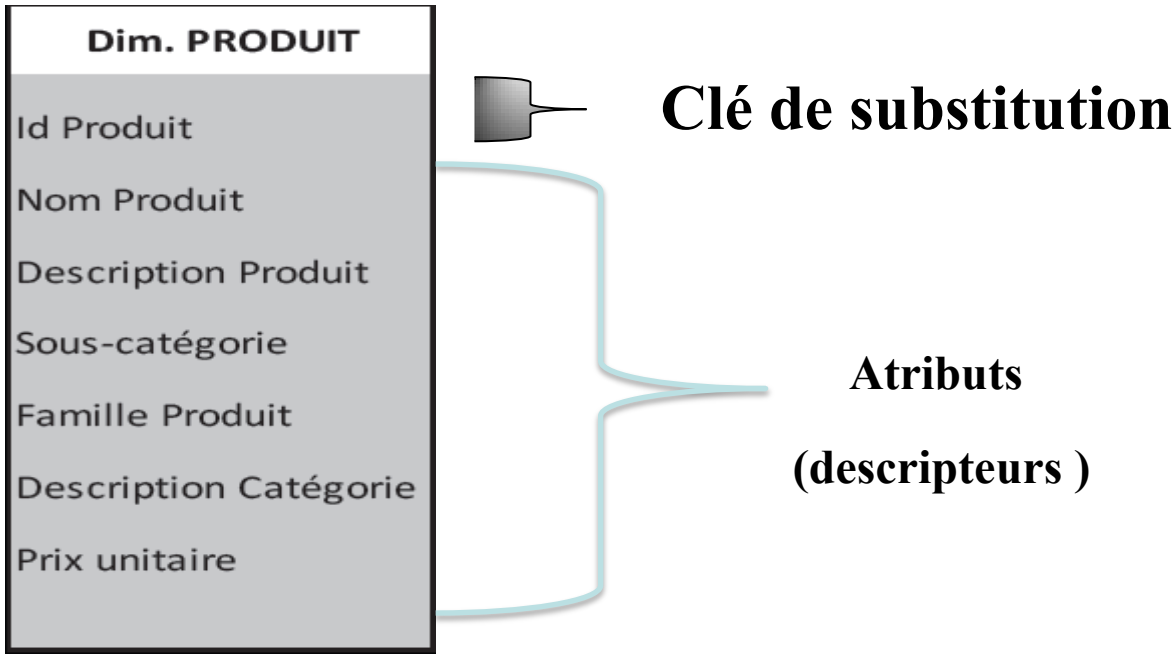

Analyse de l'entrepôt de données

❑ Table de dimension

- **Date effective:** la date de création d'un enregistrement.
- **Date retrait :** la date de retrait d'un enregistrement.
- **Indicateur effectif:** **'O'** si l'enregistrement est toujours actif (Date retrait est nulle), **'N'** sinon.

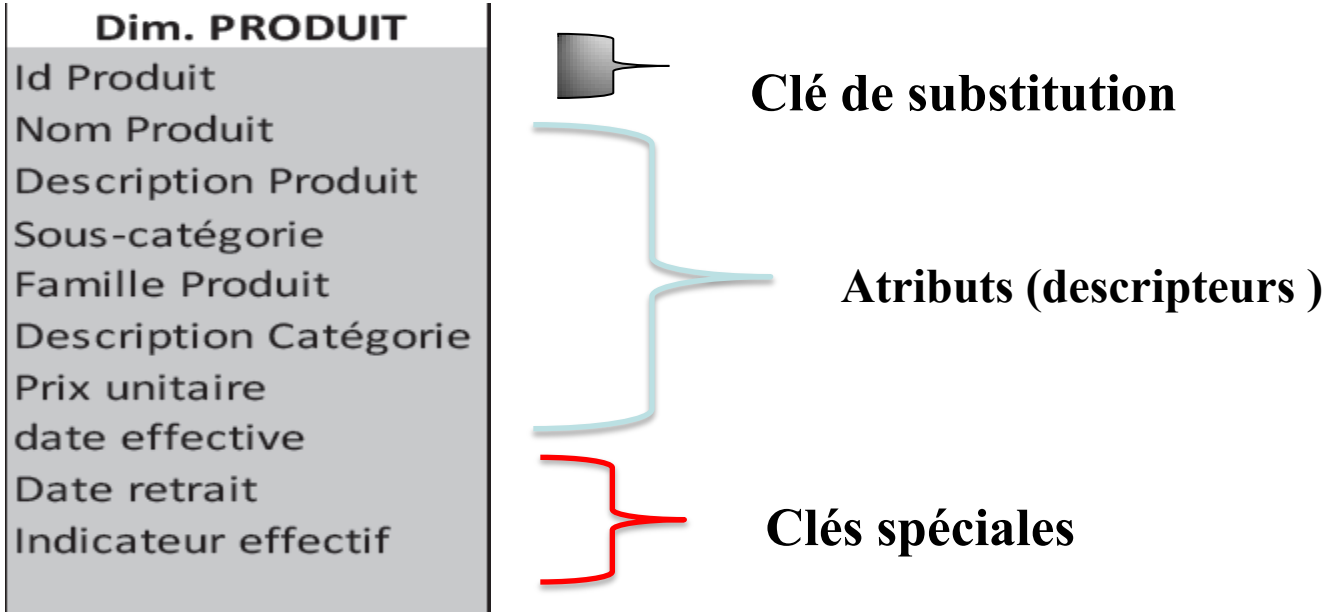

Analyse de l'entrepôt de données

❑ Table de dimension

- Commune à l'ensemble des DW.
- Reliée à toute table de faits.

Dimension Temps
Clé temps (CP)
Jour
Mois
Trimestre
Semestre
Année
Num_jour_dans_année
Num_semaine_ds_année

Analyse de l'entrepôt de données

❑ Table de dimension

- Une dimension contient des **membres organisés en hiérarchie**:
  - ➢Chacun des membres appartient à **un niveau hiérarchique** (**niveau de granularité**) particulier.
  - ➢Granularité d'une dimension: nombre de niveaux hiérarchiques.
  - ➢**Temps**:
    - *Année – Semestre – Trimestre - Mois*

Modélisation de l'entrepôt de données

❑ Nouvelle Modélisation

- **Modèle en étoile (*Star Schema*).**
- **Modèle en flocon de neige (*Snowflake Schema*).**
- **Modèle mixte (*Mixed Schema*).**
- **Modèle en constellation (*Fact constellation Schema*).**

Modélisation de l'entrepôt de données

❑ Modèle en étoile (Star Schema)

- Le **schéma en étoile** tire son nom de **sa configuration**:
  - Une **table de fait centrale** et des **dimensions**
  - Les dimensions n'ont pas de liaison entre elles.

- **Avantages:**
  - Facilité de navigation.
  - Nombre de jointures limité.

- **Inconvénients:**
  - Redondances dans les dimensions
  - Alimentation complexe.

Modélisation de l'entrepôt de données

❑ Modèle en étoile (Star Schema)

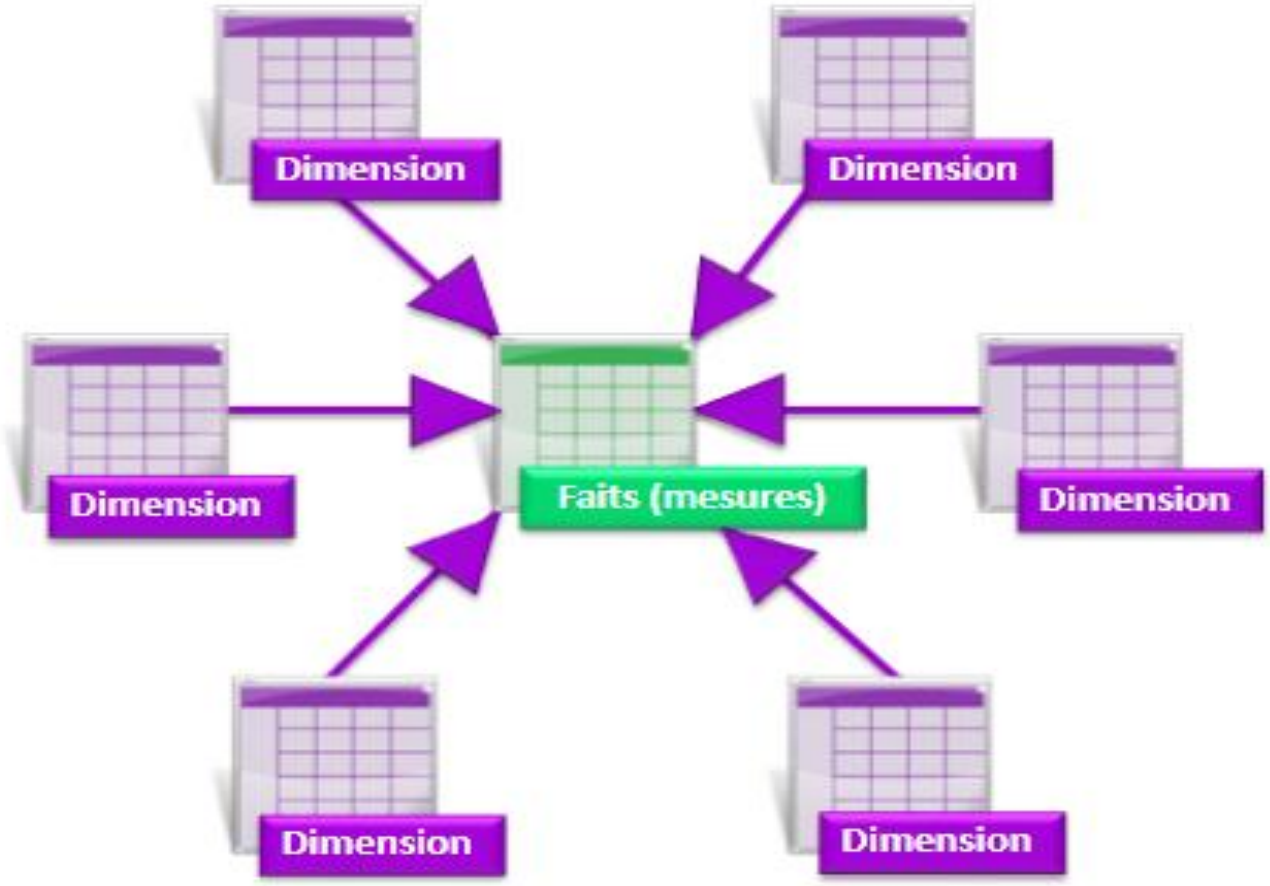

Modélisation de l'entrepôt de données

❑ Modèle en étoile (Star Schema)

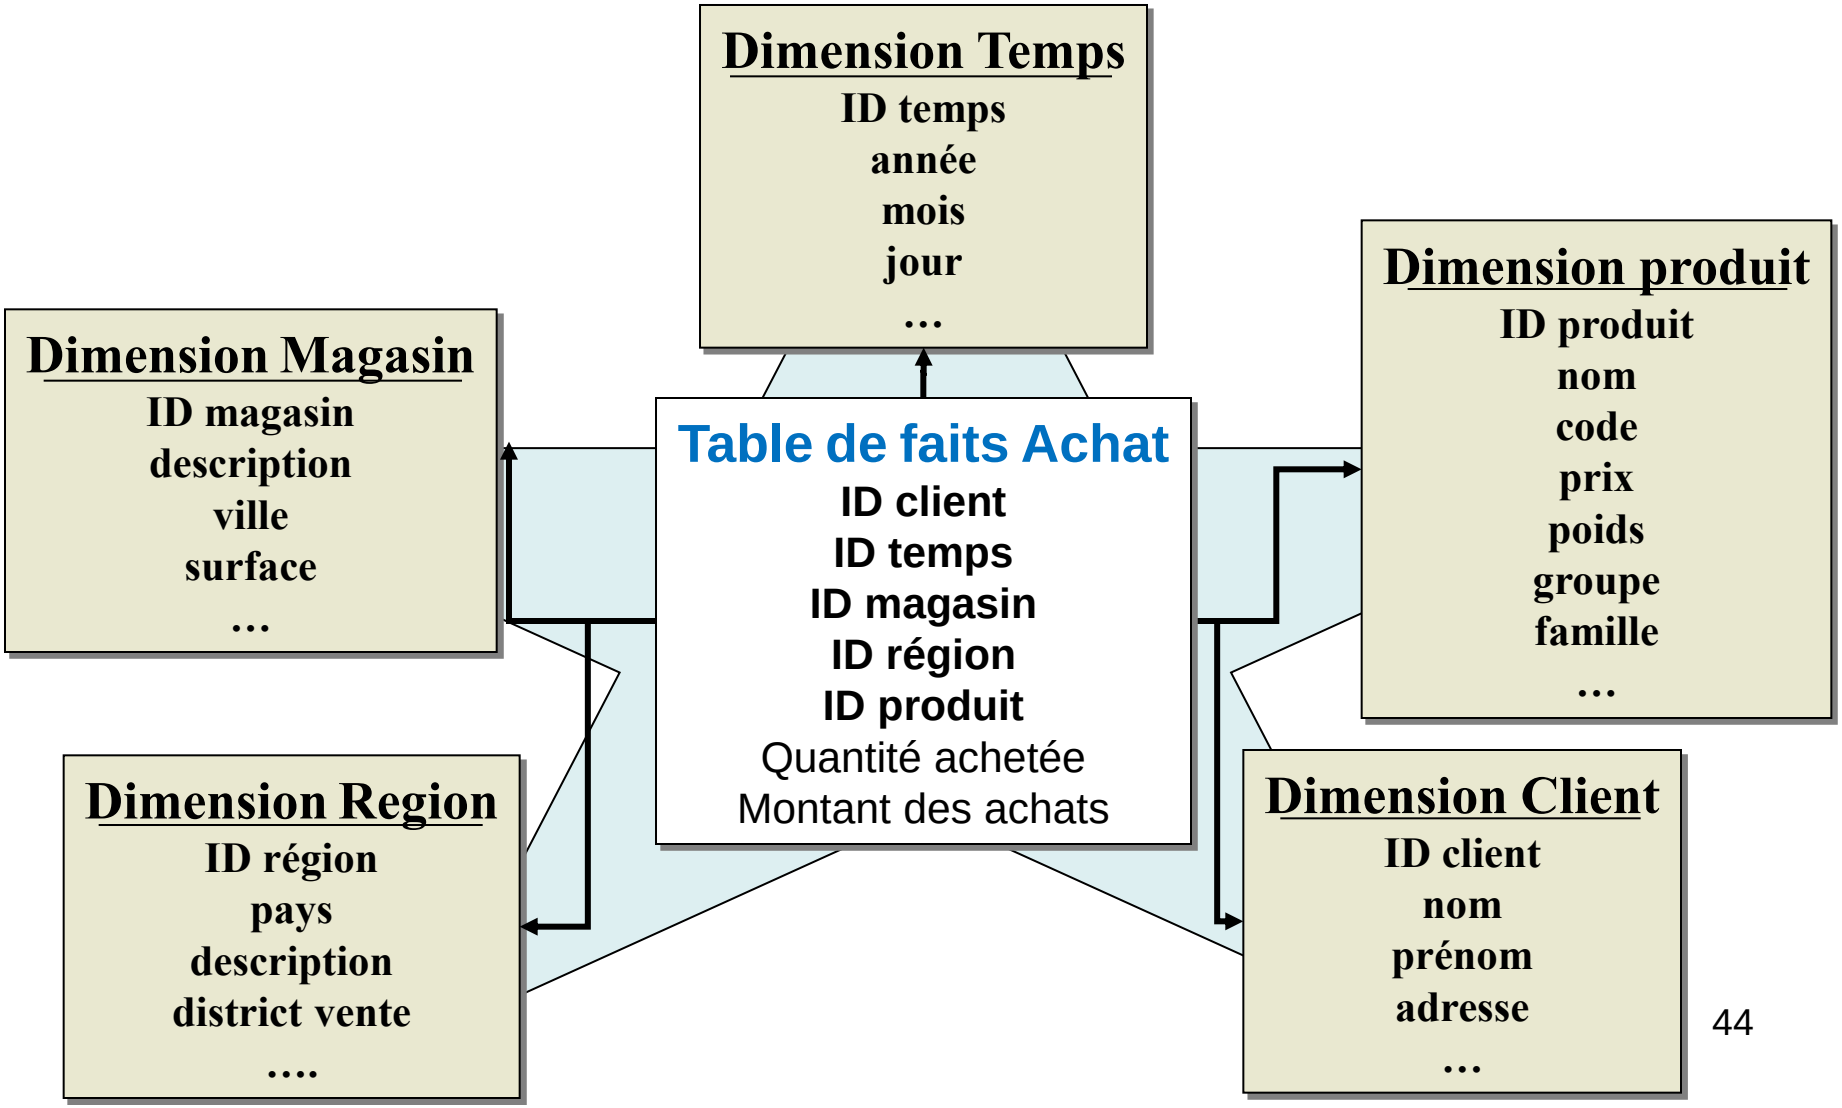

Modélisation de l'entrepôt de données

❑ Modèle en flocon de neige (Snowflack Schema)

- Une table de fait et des dimensions décomposées.
- La table de dimension de niveau hiérarchique le plus bas est reliée à la table de fait. On dit qu'elle a **une granularité la plus fine**.
- **Modèle floconné** = *Modèle en étoile* + *Dimensions normalisées.*
- **Avantages:**
  - Normalisation des dimensions.
- **Inconvénients:**
  - Modèle plus complexe (jointure).
  - Requêtes moins performantes.

Modélisation de l'entrepôt de données

❑ Modèle en flocon de neige (Snowflack Schema)

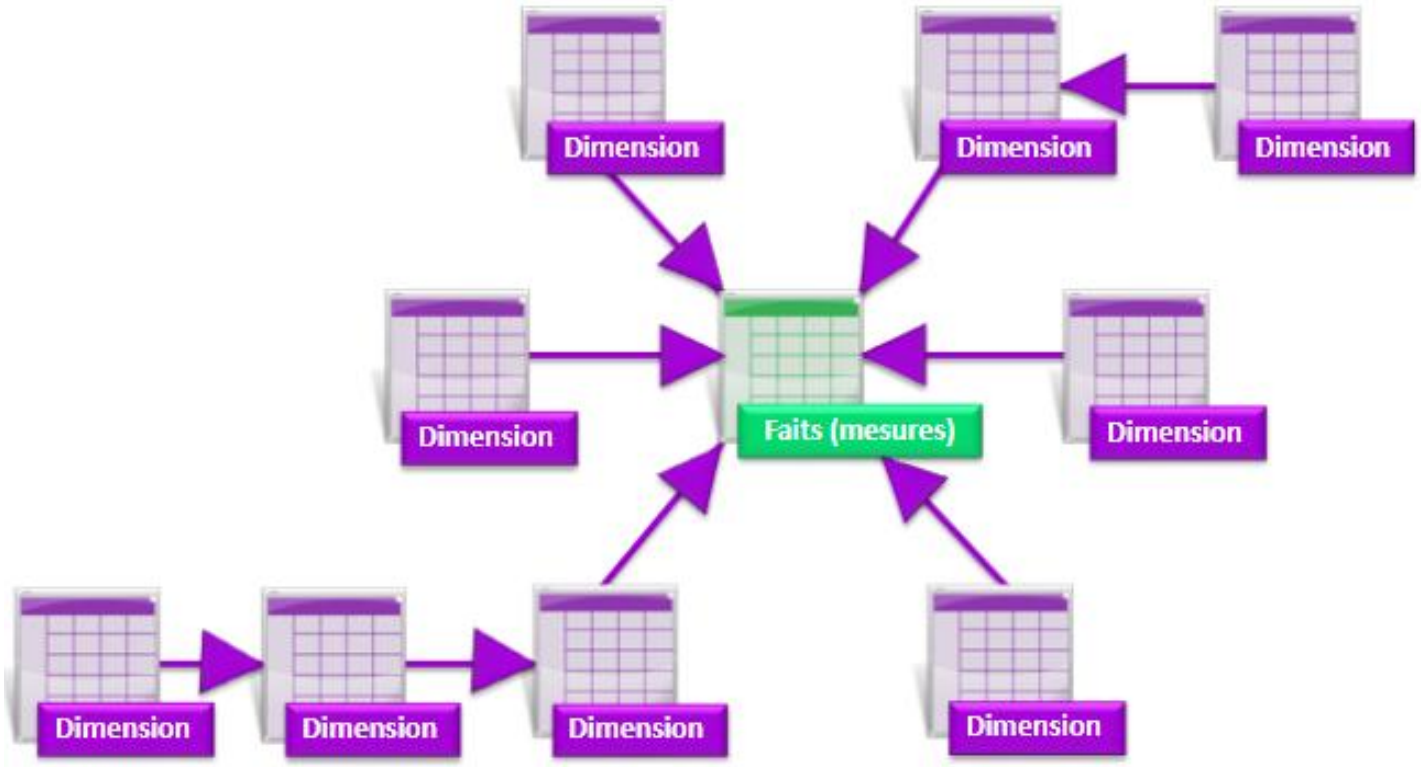

Modélisation de l'entrepôt de données

❑ Modèle en flocon de neige (Snowflack Schema)

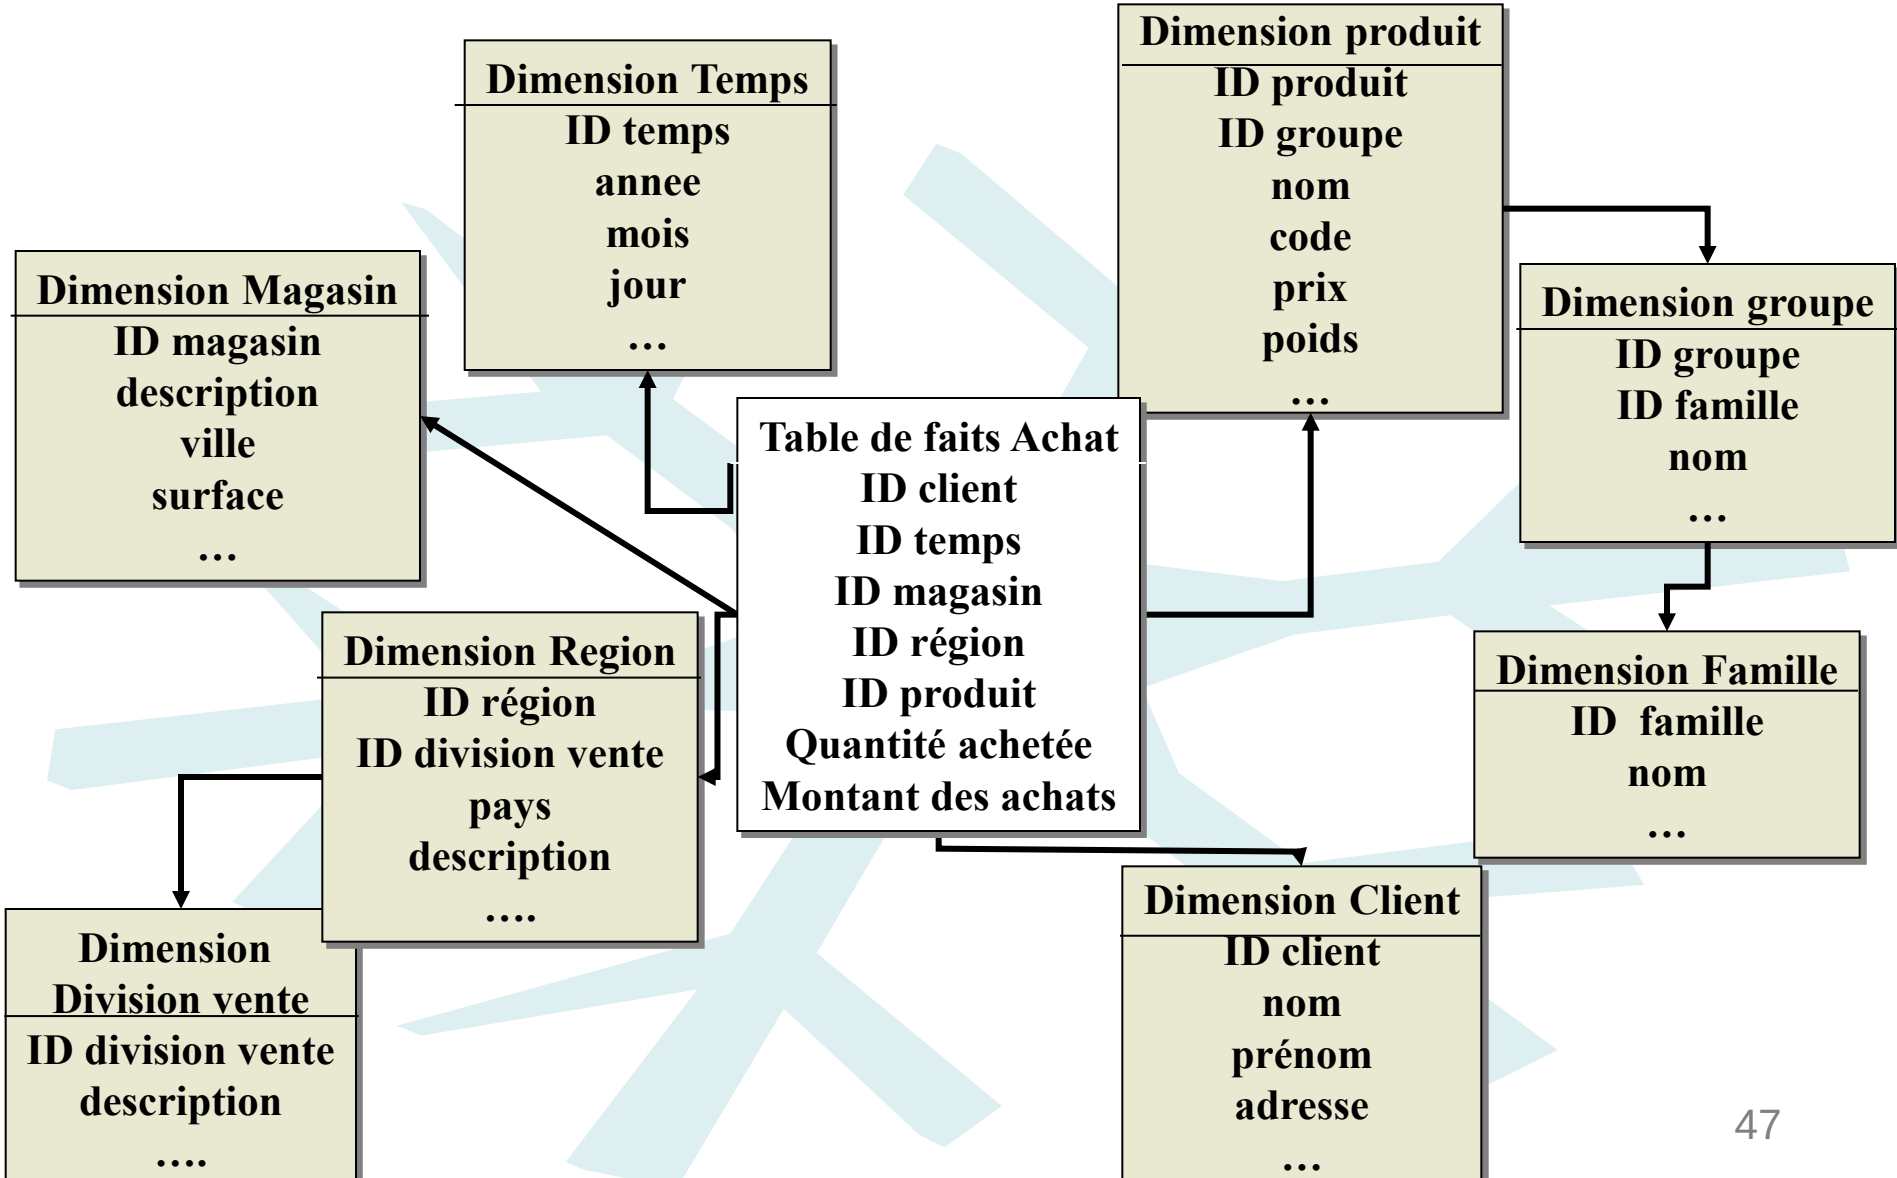

Modélisation de l'entrepôt de données

Modèle Mixte (Mixed Schema)

- Il s'agit d'une structure qui résulte de la meilleure combinaison des deux types de modèles précédents.
- **Seules quelques dimensions seront normalisées,** souvent il s'agit des plus grandes tables et celles contenant plus de redondances.

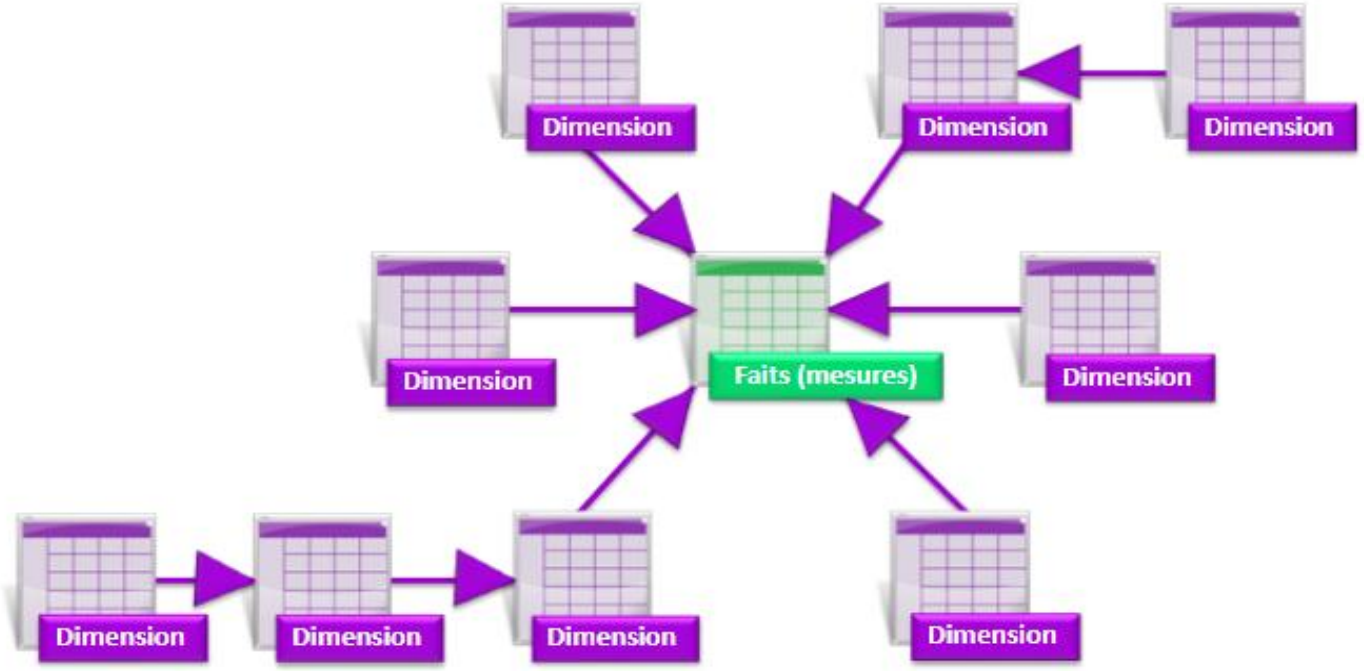

Modélisation de l'entrepôt de données

❑ Modèle en constellation (Fact constellation Schema)

- Il consiste à **fusionner** plusieurs modèles **en étoile** qui peuvent utiliser des **dimensions communes**.
- Il comprend donc **plusieurs tables de faits** et des tables **de dimensions communes** ou non à ces tables de faits.

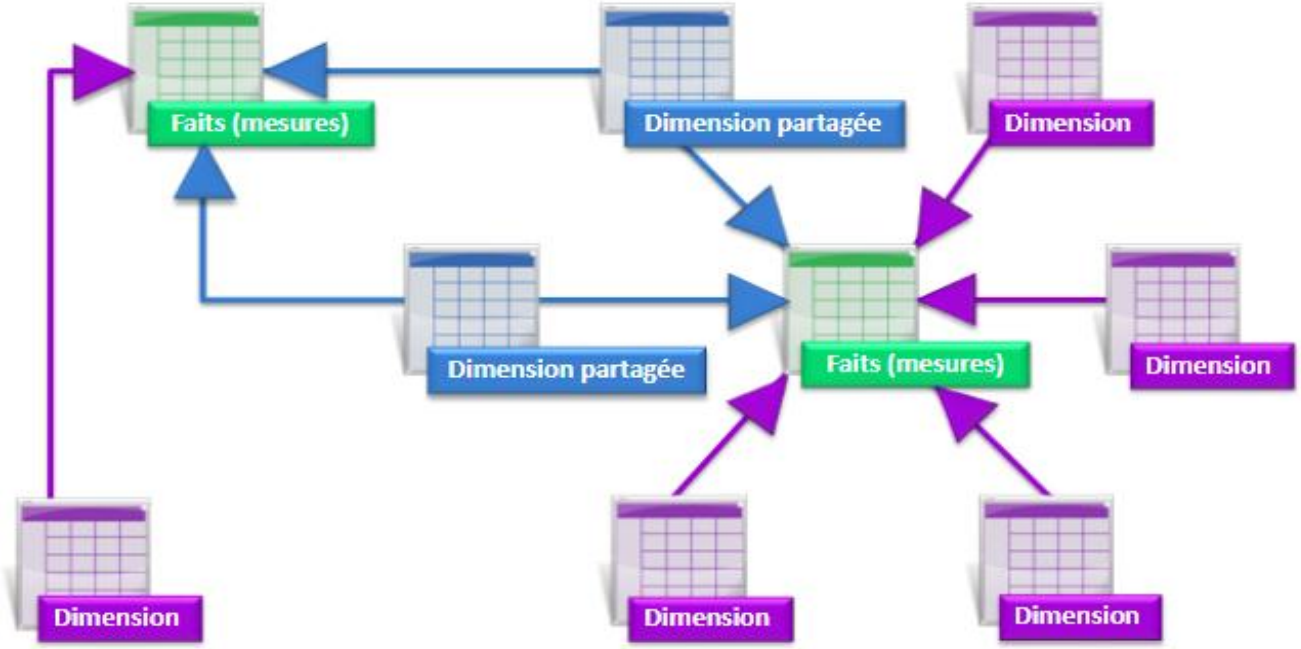

Modélisation de l'entrepôt de données

❑ Modèle en constellation (Fact constellation Schema)

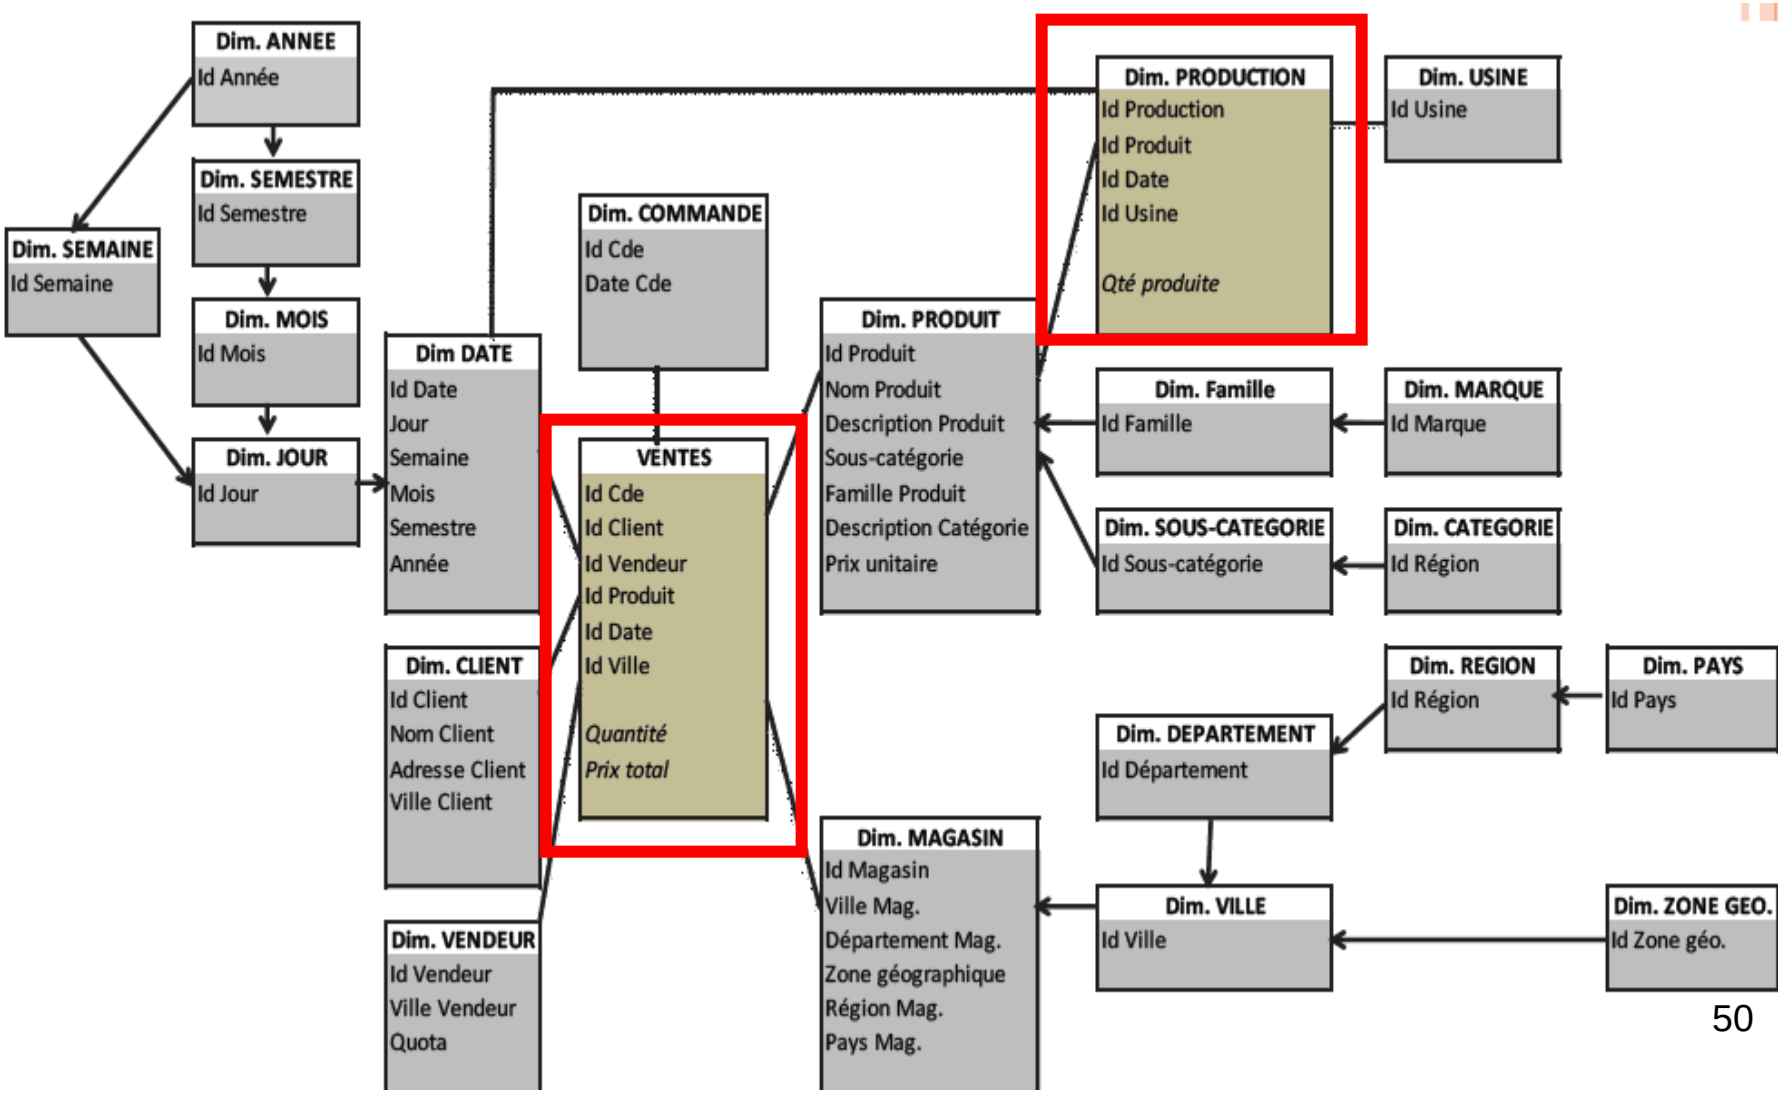

Evolution des dimensions

❑ Dimensions à évolution lente

- Dimensions **à évolution lente** (*SCD: Slowly Changing Dimension*)
  - Un client peut se marier, avoir des enfants…
  - Un produit peut changer de noms ou de formulation:
    - ✓ « yagourt à la vanille » en « yagourt saveur vanille »
- Gestion de la situation, *3 solutions*:
  1. **Écrasement de l'ancienne valeur.**
  2. **Ajout d'un nouvel enregistrement.**
  3. **Valeur d'origine / valeur courante.**

Evolution des dimensions

❑ Dimensions à évolution lente

- **Écrasement de l'ancienne valeur :**
  - Correction des informations erronées.
  - Facile à mettre en œuvre.
  - Perte de la trace des valeurs antérieures des attributs.
  - Perte de la cause de l'évolution dans les faits mesurés.

Clé produit	Description du produit	Groupe de produits
12345	IntellitiKids	Logiciel

Jeux éducatifs

Evolution des dimensions

❑ Dimensions à évolution lente

- **Ajout d'un nouvel enregistrement:**
  - Utilisation d'une clé de substitution.
  - Permet de suivre l'évolution des attributs.
  - Permet de segmenter la table de faits en fonction de l'historique.
  - Accroit le volume de la table.

Clé produit	Description du produit	Groupe de produits
12345	IntellitiKids	Logiciel
25963	IntellitiKids	Jeux éducatifs

Evolution des dimensions

❑ Dimensions à évolution lente

- **Ajout d'un nouvel attribut:**
  - Valeur origine /valeur courante.
  - Avoir deux visions simultanées des données:
    - ➢Voir les données récentes avec l'ancien attribut.
    - ➢Voir les données anciennes avec le nouvel attribut.
  - Voir les données comme si le changement n'avait pas eu lieu.
  - Inadapté pour suivre plusieurs valeurs d'attributs intermédiaires

Clé produit	Description du produit	Groupe de produits	Nouveau groupe de produits
12345	IntellitiKids	Logiciel	Jeux éducatifs

Evolution des dimensions

❑ Dimensions à évolution rapide

- Dimensions **à évolution rapide** (*RCD: Rapid Changing Dimension*) :
  - Subit des **changements très fréquents** (par ex tous les mois) des attributs dont on veut **garder l'historique**.
  - **Solution**:

    - *Isoler les attributs qui se changent rapidement.*

Evolution des dimensions

❑ Dimensions à évolution rapide

Exemple :

- Si l'on veut préserver **l'historique des changements d'adresse dans la dimension Clients** dans un pays où 70% de la population déménage une fois par année (1er juillet par exemple au Canada).

- La dimension Clients devient dans ce cas une dimension à évolution rapide.

Evolution des dimensions

❑ Dimensions à évolution rapide

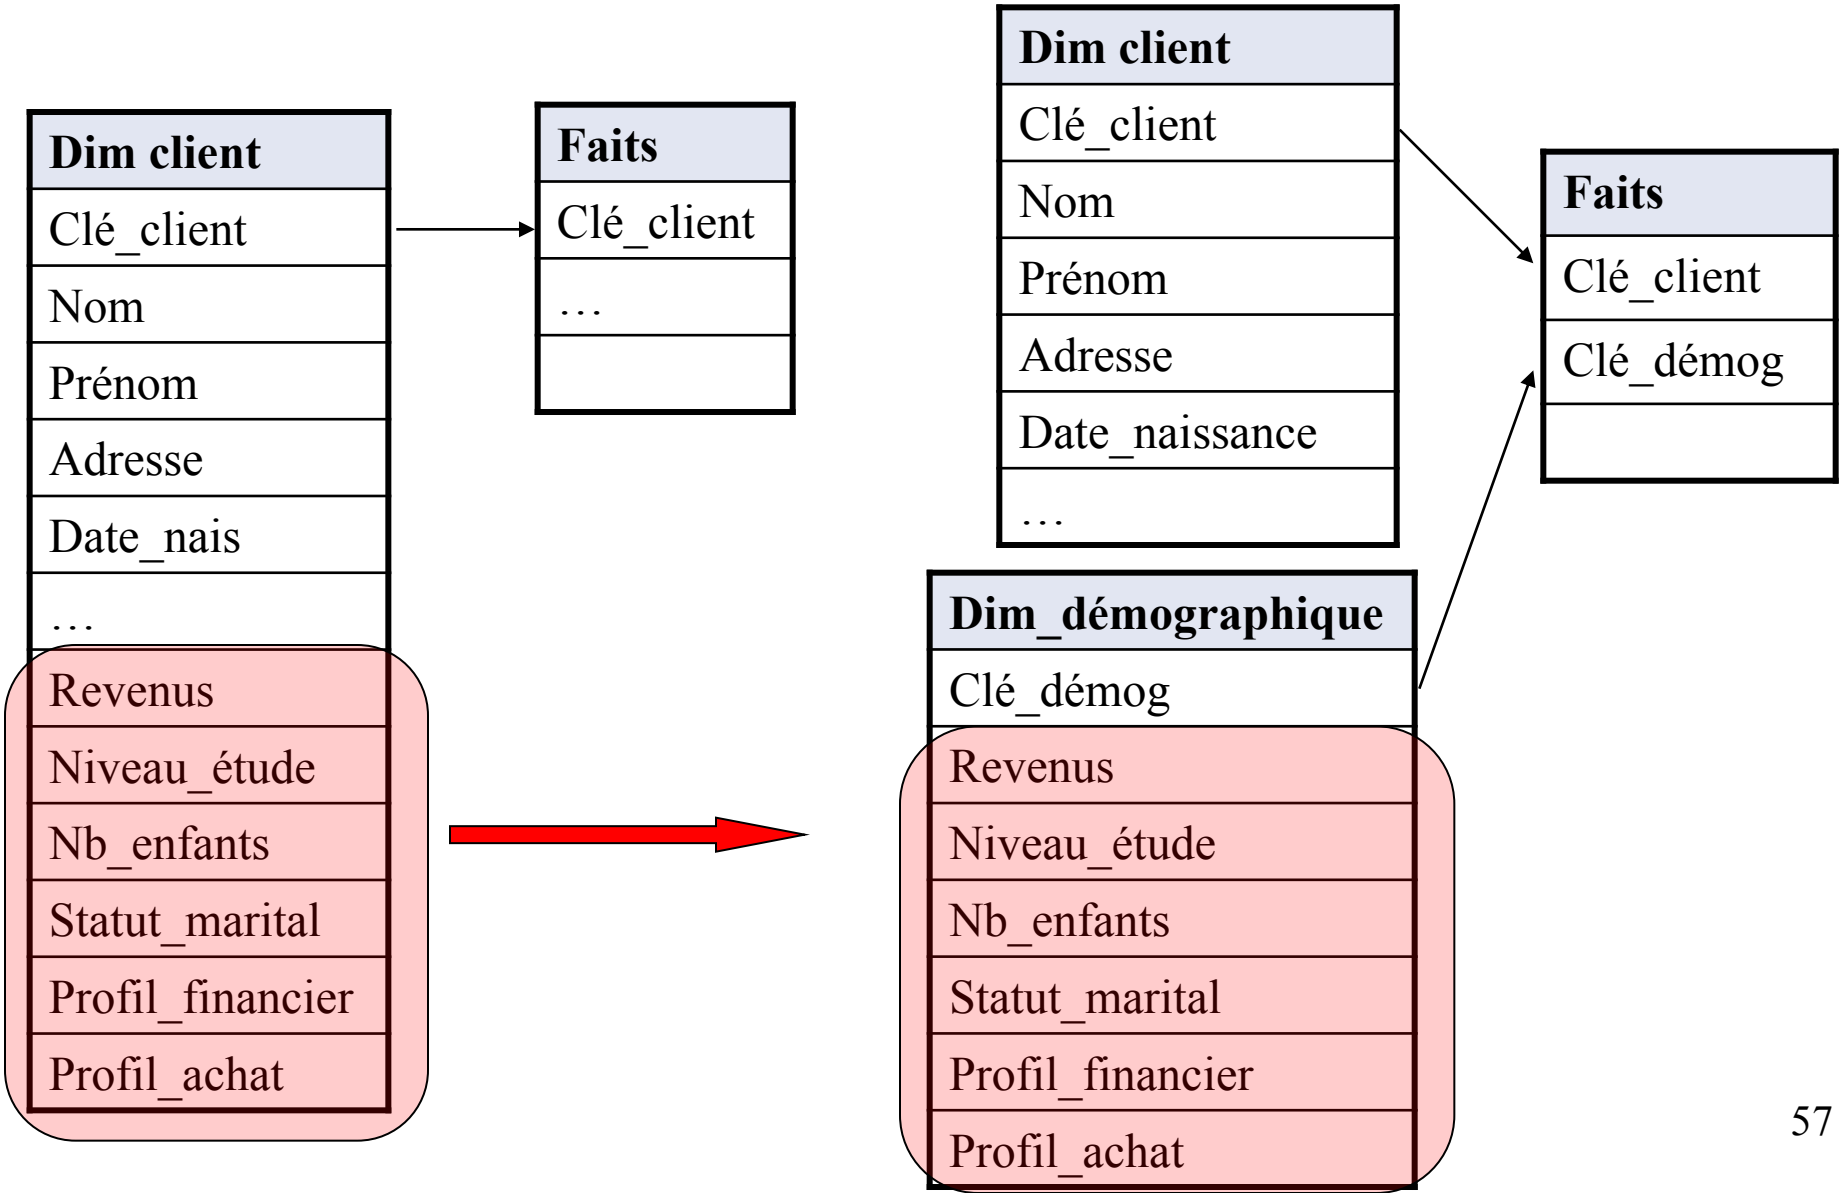

FIN