Université Cadi Ayyad Marrakech
Ecole Supérieure de Technologie Essaouira
LP ISIL Semestre 6

Module 8

Bases de Données Avancées

Chapitre III

BUSINESS INTELLIGENCE
INTÉGRATION ET ANALYSE DES DONNÉES

Pr: A. Guezzaz

Année: 2019 -2020

I. Outils d'Intégration des données: ETL

1. **ETL** (Extract Transform Load)
2. **ETL sous SQL Server**

II. Outils de navigation et d'analyse des données: OLAP

1. **OLAP** (On-Line Analysis Process)
2. **Cube OLAP**
3. **Types OLAP**
4. **OLAP sous SQL Server**

Outils d'Intégration des données

ETL

❑ ETL (Extract Transform Load)

- Il est important de savoir que la réalisation **de l'ETL constitue 70%** d'un projet décisionnel en moyenne.
  - Et ce n'est pas pour rien, l'implémentation de **ce système est complexe.**
  - Avoir une **mauvaise information** dans l'entrepôt:
    - ➢ **données fausses, donc inutilisables, décisions erronées**.
- ETL permet de découvrir, analyser et extraire les données à partir de sources **hétérogènes**.
- ETL permet de **nettoyer** et **standardiser** les données.
- ETL permet de **charger** les données dans un **entrepôt**.

❑ ETL (Extract Transform Load)

- Pour alimenter DW, un ETL (Extract Transform Load) est utilisé.
- Décrit les données, leur provenance et les transformations effectuées.
- Permet **d'agréger**, **classifier**, **normaliser** et **nettoyer** les données extraites.
- Les concepteurs doivent mettre en place une stratégie de mise à jour **pour l'historisation et prévoir la volumétrie.**
- Les **ETL** peuvent être **intégrés** aux **outils de modélisation** ou de **restitution**.

❑ ETL (Extract Transform Load)

- Les **ETL** peuvent se concevoir de deux façons:
  - **Manuellement :** en lançant des scripts (PL/SQL, …).
  - **Avec des logiciels** (qui sont chers).
- **Identifier les sources:**
  - **Où** ?: fichiers, SGBDR, ERP, Internet, …
  - **Comment**?: LAN, MAN, WAN, transferts des fichiers.
  - **Quand** ?

❑ ETL (Extract Transform Load)

❑ Problèmes rencontrés

- Souvent peu d'entreprises ont des logiciels qui permettent la création d'ETL, car ce sont des outils coûteux. **Il faut souvent réaliser l'alimentation à la main.**
- **Penser à la volumétrie des sources de données et à la fréquence de mise à jour.**
- Faire attention aux environnements trop mouvants, **c'est à dire aux mises à jour trop fréquentes.**
- Synchroniser l'alimentation de différents Data Mart **sinon on peut obtenir des rapports faux dans la phase de restitution.**

❑ ETL (Extract Transform Load)

❑ Extraction

- Extraire des données des systèmes de production.
- Dialoguer avec **différentes sources**:
  - **Base de données,**
  - **Fichiers,**
  - **……**
- Utilise **divers connecteurs**:
  - **ODBC,**
  - **OLE DB**
  - **SQL natif,**
  - **Fichiers plats**

❑ ETL (Extract Transform Load)

❑ Transformation

- Rendre **cohérentes** les données des différentes sources.
  - Transformer, nettoyer, trier, unifier les données.
  - Exemple: unifier le format des dates.

(MM /JJ /AA ⇨ JJ /MM /AA)

- **Etape très importante qui garantit la cohérence et la fiabilité des données.**

❑ ETL (Extract Transform Load)

❑ Chargement

- Insérer ou modifier les données de l'entrepôt.
- Utilisation **des connecteurs**:
  - **ODBC,**
  - **SQL natif,**
  - **Fichiers plats**

❑ ETL sous SQL Server

SQL Server Intégration Services

(SSIS)

un outil de gestion de flux de données.

Outils de navigation d'analyse des données

OLAP

❑ OLAP (On-Line Analysis Process)

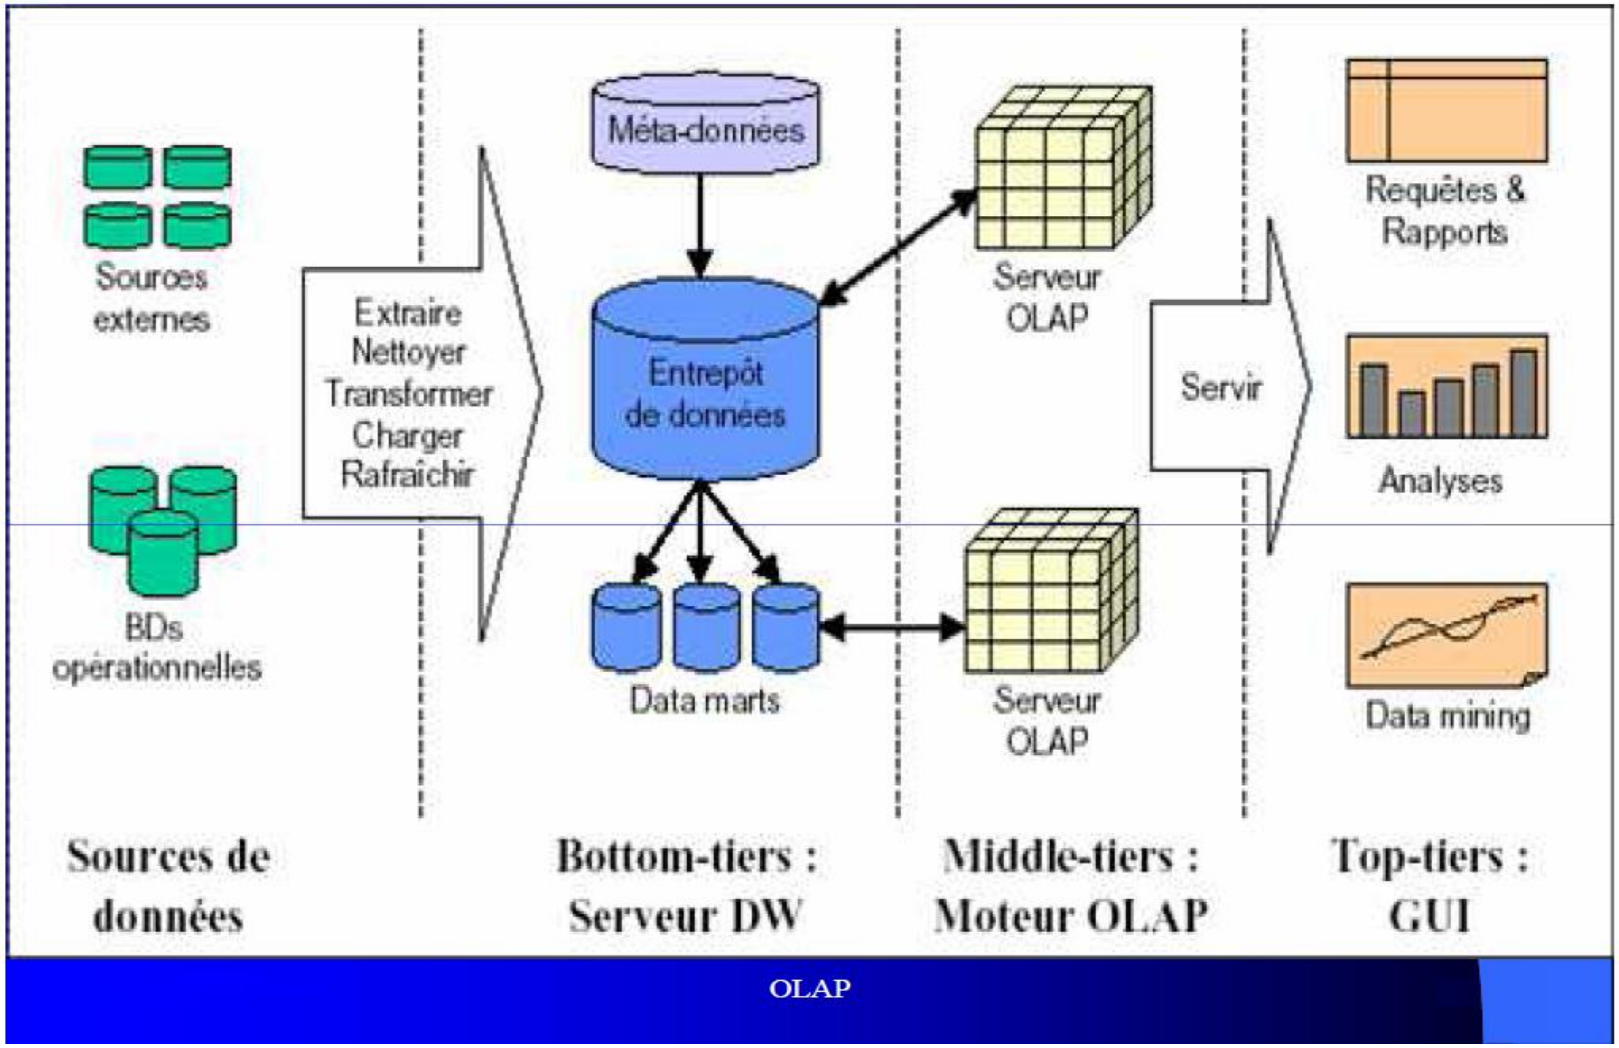

❑ OLAP (On-Line Analysis Process)

« Il s'agit d'une **catégorie de logiciels** axés sur **l'exploration et l'analyse rapide** des données selon une **approche multidimensionnelle** à plusieurs **niveaux d'agrégation** »

(Caron, 1998)

❑ OLAP (On-Line Analysis Process)

❑ Objectifs attendus

- **Catégorie de logiciels:**
  - S'exprime par une grande quantité de produits logiciels disponibles sur le marché.
- **Exploration et analyse rapide :**
  - **OLAP** vise à assister l'utilisateur dans son analyse en lui facilitant l'exploration de ses données et en lui donnant la possibilité de les traiter rapidement.
    - **Facilité et Rapidité.**

❑ OLAP (On-Line Analysis Process)

❑ Objectifs attendus

- **Facilité:**
  - L'utilisateur n'a pas besoin de maîtriser des **langages d'interrogation** et des **interfaces complexes**.
  - L'utilisateur interroge directement les données.
- **Rapidité:**
  - OLAP exploite une **pré-agrégation** des données.
  - L'utilisateur peut **se concentrer sur son analyse** et non sur le processus (moyens utilisés pour l'analyse).

❑ Cube OLAP

- **Dimension:**
  - Axe d'analyse selon lequel les données seront analysées.
    - Ex. Temps, Produits
- **Membre:**
  - Valeur de dimension
  - Une dimension possède des instances, également appelées membres.
- **Mesure / Fait**:
    - Ex. coût des travaux, nombre d'accidents, ventes, dépenses.

- **Cube**:
  - Un ensemble de mesures organisées selon un ensemble de dimensions.
    - Ex. Un cube de ventes qui comprend:
      - » Dimensions Temps, Produit, Magasin.
        - » Mesure Ventes en Dh.

❑ Cube OLAP

Les **cubes OLAP** ont les caractéristiques suivantes:

1. Obtenir des informations **déjà agrégées** selon les besoins de l'utilisateur.
2. **Simplicité et rapidité d'accès**.
3. **Capacité à manipuler** les données agrégées selon différentes dimensions.
4. Un cube utilise les fonctions classiques d'agrégation: **MIN, MAX, COUNT, SUM, AVG.**

❑ Cube OLAP

- **Comment peut-on utiliser ce cube ?**
- Nous allons nous intéresser aux diverses vues du cube ci-dessous:

.

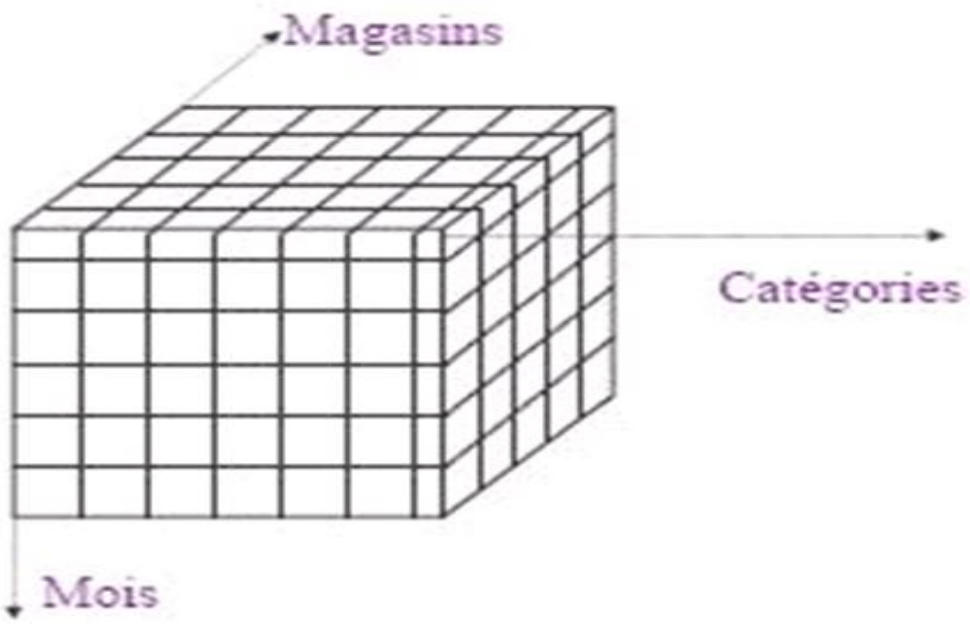

❑ Cube OLAP

Vue n° 1 :

- On s'intéresse à toutes les ventes du **magasin x**.
- **Toutes catégories** durant **touts les mois**).

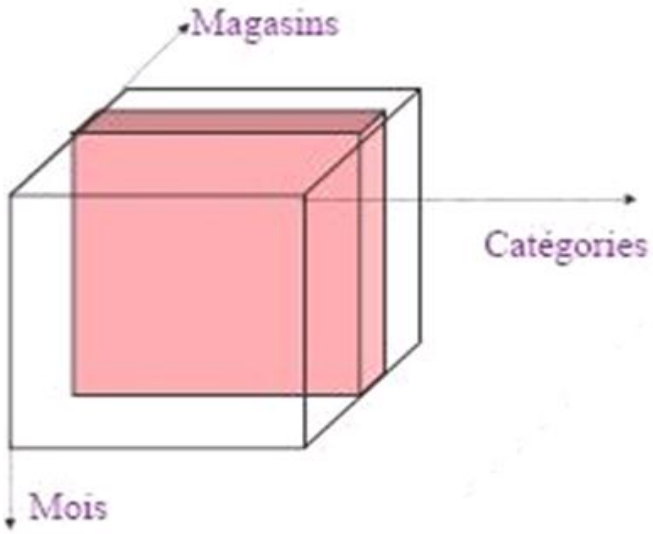

Vue n° 2 :

- On s'intéresse aux ventes de la **catégorie « Cat y».**
- **Tous les magasins** durant **touts les mois**.

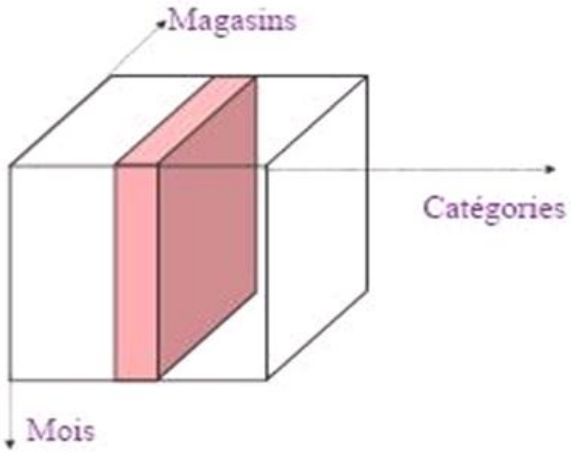

❑ Cube OLAP

Vue n° 3:

▪On s'intéresse à toutes les ventes durant le **mois z.**

▪**Toutes catégories** et dans **tous les magasins**.

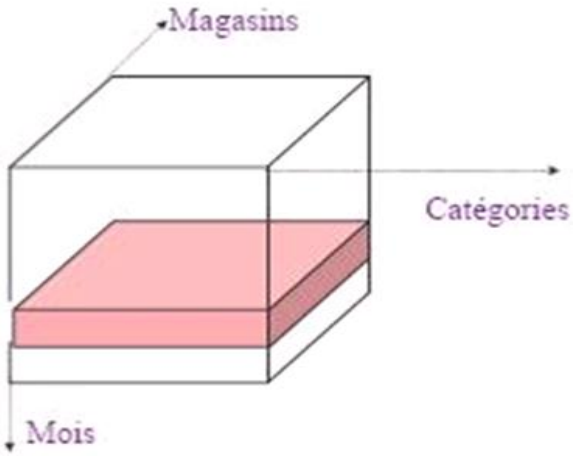

Vue n° 4:

▪On s'intéresse aux ventes du **magasin x.**

▪Dans la **catégorie « Cat y"** durant le **mois z**.

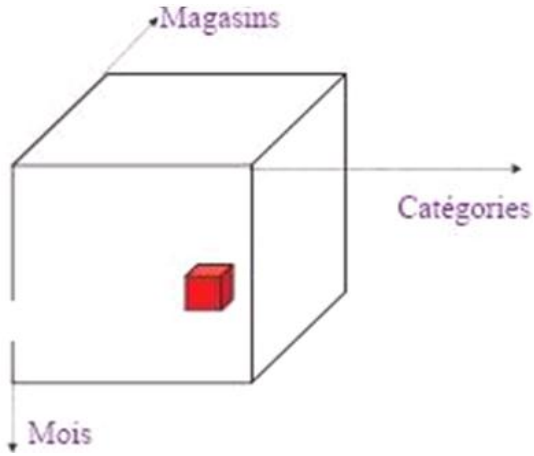

❑ Cube OLAP

❑ Multi-représentations du Cube Ventes

- cube : Ventes
- fait : Ecrans Plats, Lyon, 01/02/08, 9
- référence: Ecrans Plats, Lyon, 01/02/08
- mesure : 9
- membre/paramètre : Lyon
- dimension : Villes
- niveau : Villes

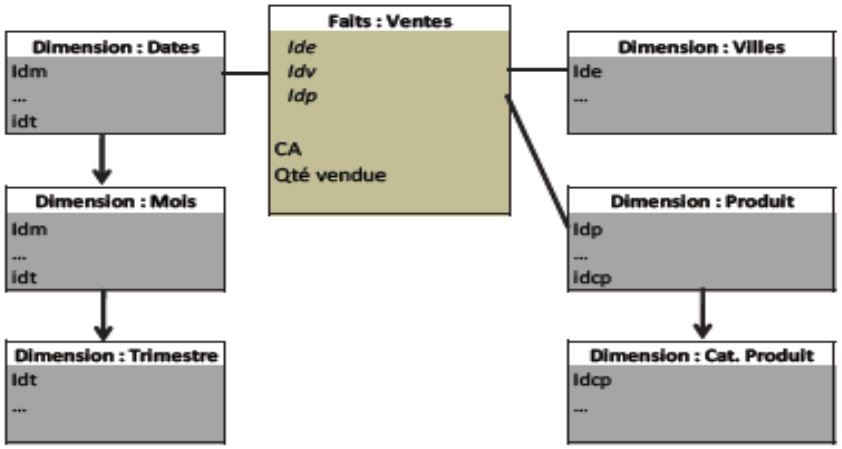

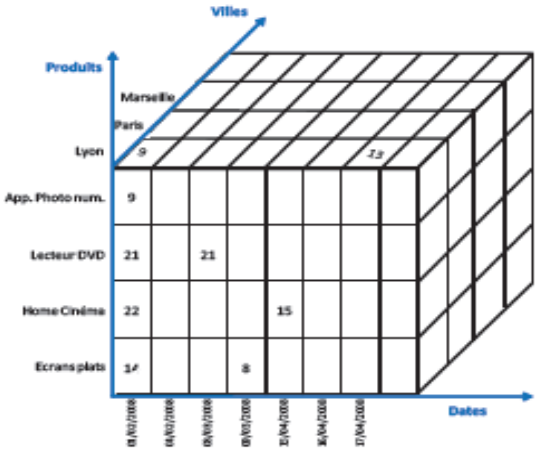

Fonction d'agrégation					Catégorie Produits	C1		C2			C3	
					Produits	P1	P27	P14	P23	P25	P3	P11
					Villes	v1	v3	v1	v12	v2	v8	v10
Trimestre	t1	Mois	m1	Dates	d1							
			m2		d2							
			m3		d3							
	t2		m4		d4							
			m5		d5							
			m6		d6							
	t3		m7		d7							
			m8		d8							
			m9		d9							

❑ Cube OLAP

- **But:** Visualisation et utilisation d'un fragment de l'Hypercube.
- **Roll-up**: Supprimer des détails d'une dimension, passage de mesures détaillées à résumées en remontant dans la hiérarchie de dimension.
- **Drill-down**: Ajouter des détails à une dimension, descendre dans la hiérarchie de la dimension.
- **Drill-across**: passer d'un membre de dimension à un autre.
- **Rotate (Pivoter):** Rotation des dimensions (axes) du cube pour fournir une vue alternative des données.
- **Slicing:** Sélection des **tranches du cube** par des prédicats selon **une dimension** et extraction d'une tranche d'informations.
- **Dicing (ou Scoping):** extraction d'un **sous-cube.**
- **Distribuer ou recalculer** des valeurs de mesures,…

❑ Cube OLAP

❑ Opération d'agrégation: Roll up

- **Roll up (**Forage vers le haut**)** ou agrégation de données: **Passage de mesures détaillées à résumées** en remontant dans la hiérarchie de la dimension. (Ex. visualiser les ventes par année au lieu de par mois).
- **Roll up** sur la dimension **''Produits''**

Villes		Lyon		Marseille		Paris	
Mesures		CA	Qté vendue	CA	Qté vendue	CA	Qté vendue
Dates	01/02/08	54 100,00 €	71	20 140,00 €	20	30 000,00 €	62
	04/02/08	11 500,00 €	23	9 600,00 €	27	23 000,00 €	37
	08/03/08	7 200,00 €	24	50 000,00 €	18	8 000,00 €	40
	09/03/08	20 000,00 €	14	5 200,00 €	14	5 000,00 €	3
	15/04/08	6 000,00 €	15				
	16/04/08	8 700,00 €	51	5 500,00 €	13	7 500,00 €	12
	17/04/08			5 200,00 €	23	1 400,00 €	3
	22/04/08			3 600,00 €	6		
	23/04/08			2 000,00 €	6		
	24/04/08			1 500,00 €	3		

❑ Cube OLAP

❑ Opération d'agrégation: Roll up

- **Roll up** sur les deux dimensions **‘’Produits”** et **"Dates"**

Villes	Lyon		Marseille		Paris	
Mesures	CA	Qté vendue	CA	Qté vendue	CA	Qté vendue
	107 500,00 €	198	101 240,00 €	130	74 900,00 €	157

- **Roll up** sur les trois dimensions **"Produits","Dates"** et **"Villes"**

Villes		
Mesures	CA	Qté vendue
	283 640,00 €	485

❑ Cube OLAP

❑ Opération d'agrégation: Drill-Down

- **Drill down:** forage de données vers le bas.
- **Drill down** sur la mesure 'CA' selon la dimension **''ville ''**

Villes		
Mesures	CA	Qté vendue
	283 640,00 €	485

???

Le résultat du **Drill down** donne:

Villes	Lyon		Marseille		Paris	
Mesures	CA	Qté vendue	CA	Qté vendue	CA	Qté vendue
	107 500,00 €	198	101 240,00 €	130	74 900,00 €	157

❑ Cube OLAP

❑ Opération d'agrégation: Drill-Down

- **Drill down** sur la mesure 'CA' selon la valeur **"Lyon"' de** la dimension **''ville ''**

Villes	Lyon		Marseille		Paris	
Mesures	CA	Qté vendue	CA	Qté vendue	CA	Qté vendue
	107 500,00 €	198	101 240,00 €	130	74 900,00 €	157

???

- Le résultat du **Drill down** donne:

	Villes	Lyon	
	Mesures	CA	Qté vendue
		107 500,00 €	198
Dates	01/02/2008	54 100,00 €	71
	04/02/2008	11 500,00 €	23
	08/03/2008	7 200,00 €	24
	09/03/2008	20 000,00 €	14
	15/04/2008	6 000,00 €	15
	16/04/2008	8 700,00 €	51

❑ Cube OLAP

❑ Opération d'agrégation: Slice & Dice

Slice & Dice : Opération de sélection et de projection des données:

Ville ="Paris" et Dates <10/03/2008

	Villes	Paris							
	Produits	Ecrans plats		Home Cinéma		Lecteur DVD		App. Photo num.	
	Mesures	CA	Qté vendue	CA	Qté vendue	CA	Qté vendue	CA	Qté vendue
Dates	01/02/2008	20 000,00 €	13	4 000,00 €	14	6 000,00 €	35		
	04/02/2008	9 500,00 €	7	13 500,00 €	30				
	08/03/2008					8 000,00 €	40		
	09/03/2008	5 000,00 €	3						

❑ Types OLAP

L'architecture OLAP consiste en **trois** services :

1. **Base de données :**
   - Doit supporter les données agrégées ou résumées.
   - Les données qu'il contient peuvent provenir d'un entrepôt DW ou d'un marché de données (DM).
   - Doit posséder une structure multidimensionnelle.
2. **Serveur OLAP :**
   - Gère la structure multidimensionnelle dans le SGBD.
   - Gère l'accès aux données de la part des utilisateurs.
3. **Module client :**
   - Permet aux usagers de manipuler et d'explorer les données
   - Affichage sous forme de graphique et de tableaux.

❑ Types OLAP

❑ MOLAP (OLAP Multidimensionnel)

- Selon le type de **base de données accédé**, plusieurs configurations sont possibles:
  - **Multidimensionnelle,**
  - **Relationnelle,**
  - **Hybride.**

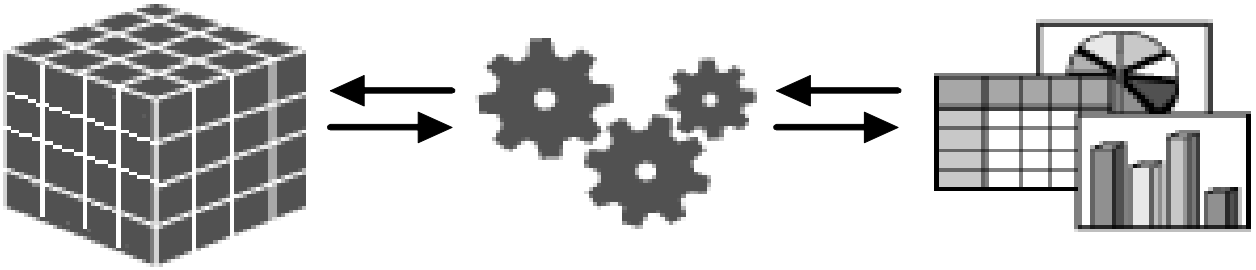

Base de données multidimensionnelle (hypercube) **Serveur MOLAP** **Client OLAP**

❑ Types OLAP

❑ ROLAP (OLAP Relationnel)

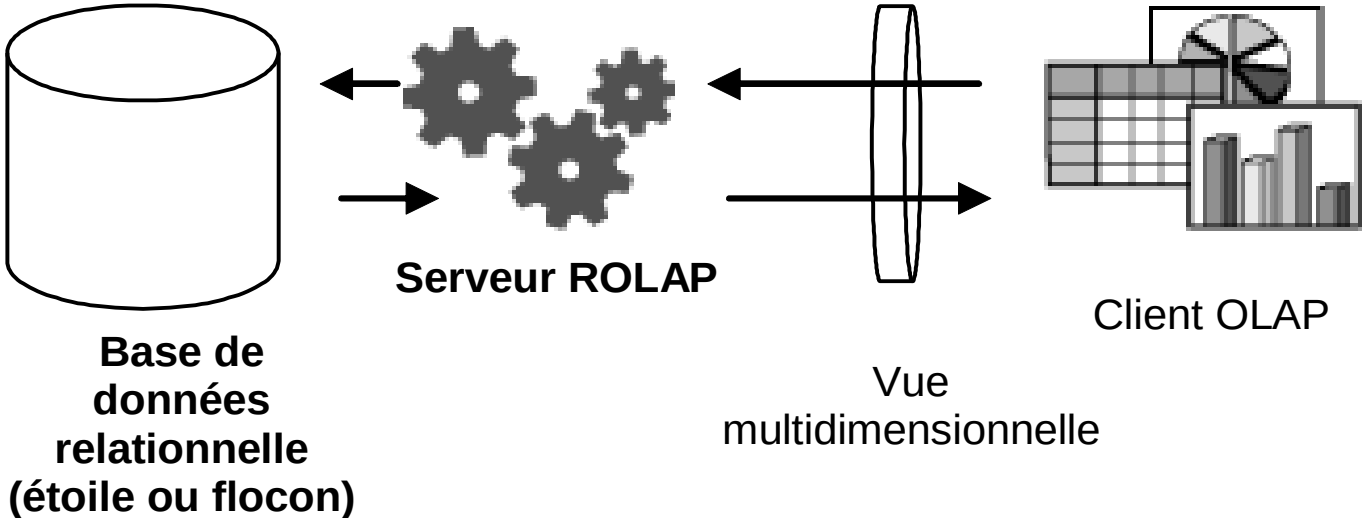

❑ Types OLAP

❑ HOLAP (OLAP Hybride)

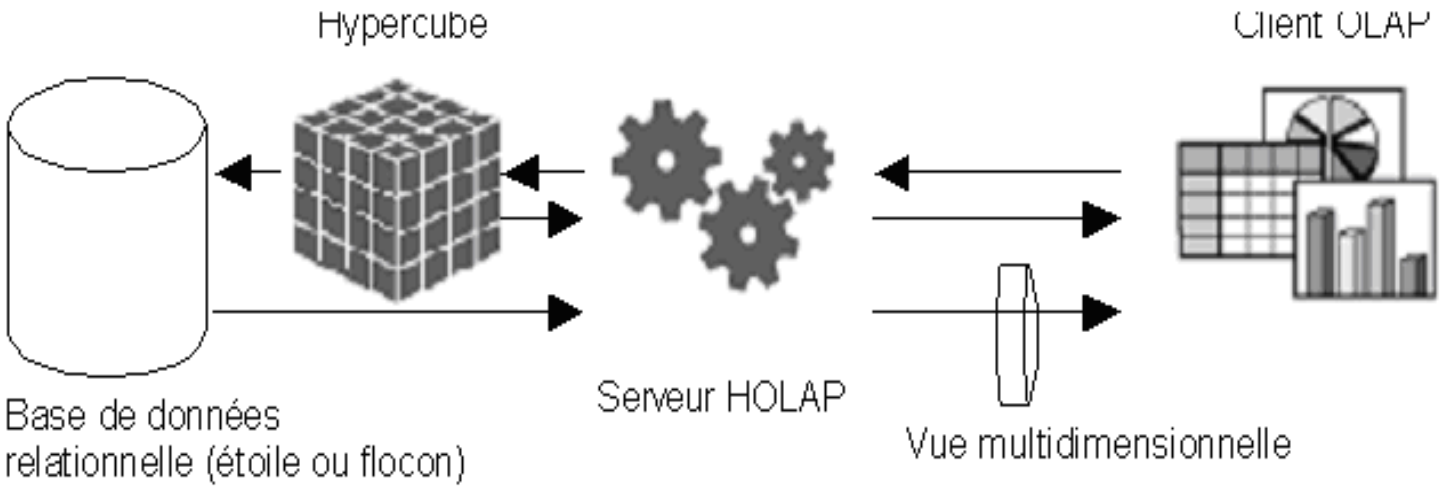

❑ Types OLAP

- **Intelligent miner d'IBM:**
  - Classification, association, régression, analyse de séquences, regroupement.
- **Entreprise miner de SAS:**
  - Multiples outils d'analyse statistique, classification, …
- **Clémentine de SPSS:**
  - En plus des fonctionnalités classiques, l'utilisateur peut rajouter ses propres algorithmes.
- **DBMiner:**
  - Il se distingue par le fait qu'il incorpore les fonctionnalités d'OLAP.

❑ OLAP SOUS SQL SERVER

❑ Cube avec SQL SERVER

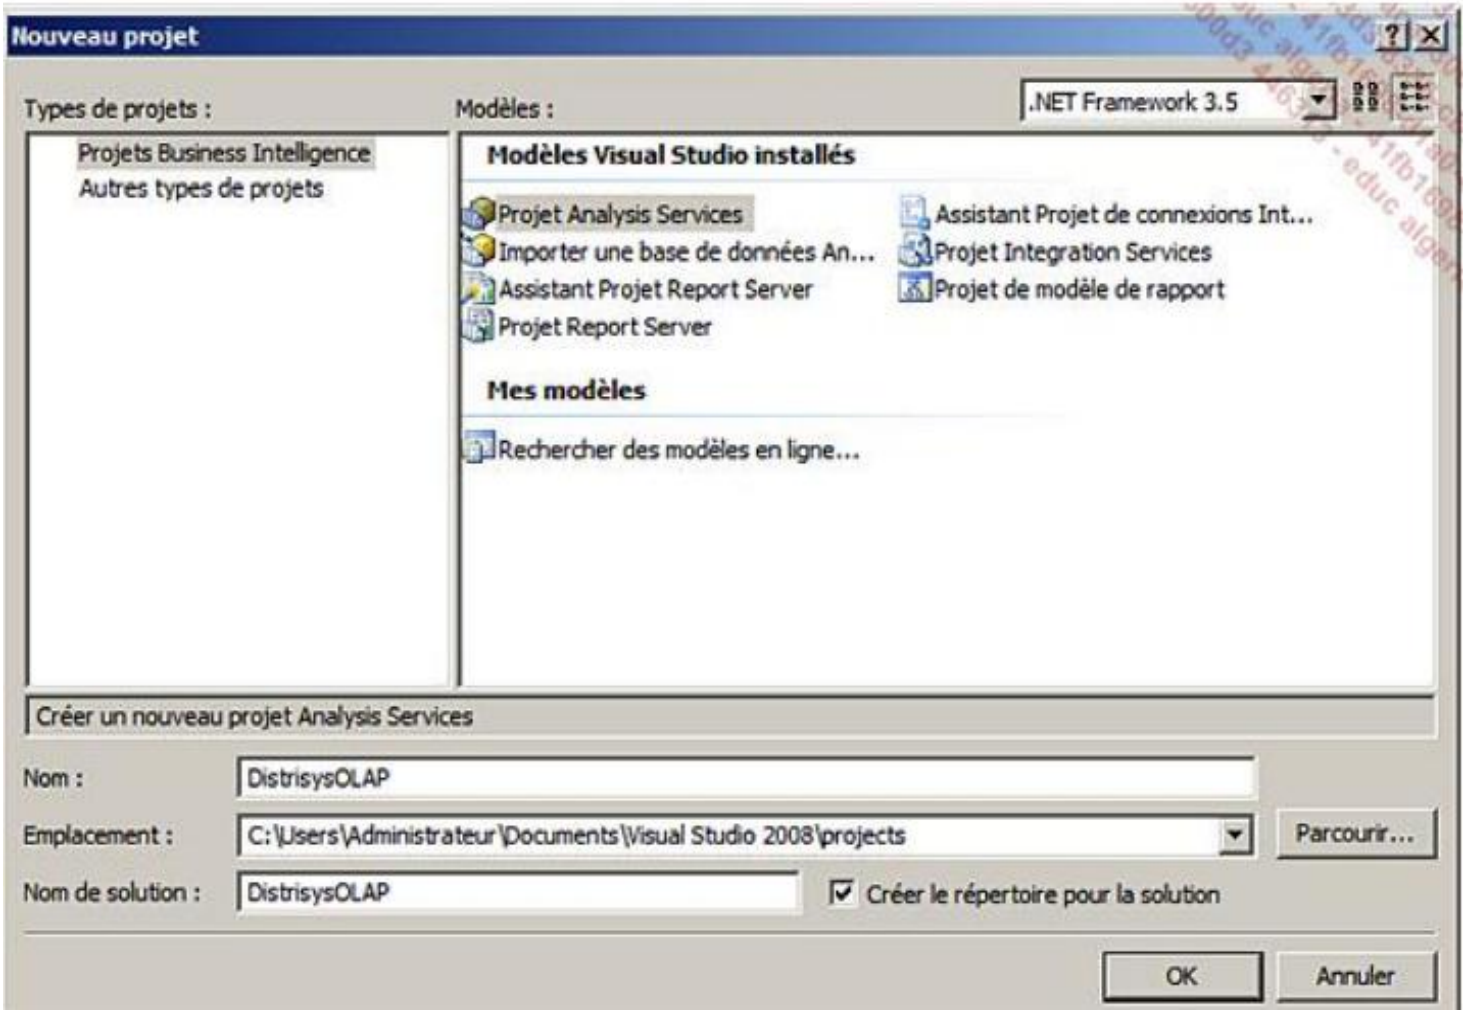

❑ OLAP SOUS SQL SERVER

❑ Cube avec SQL SERVER

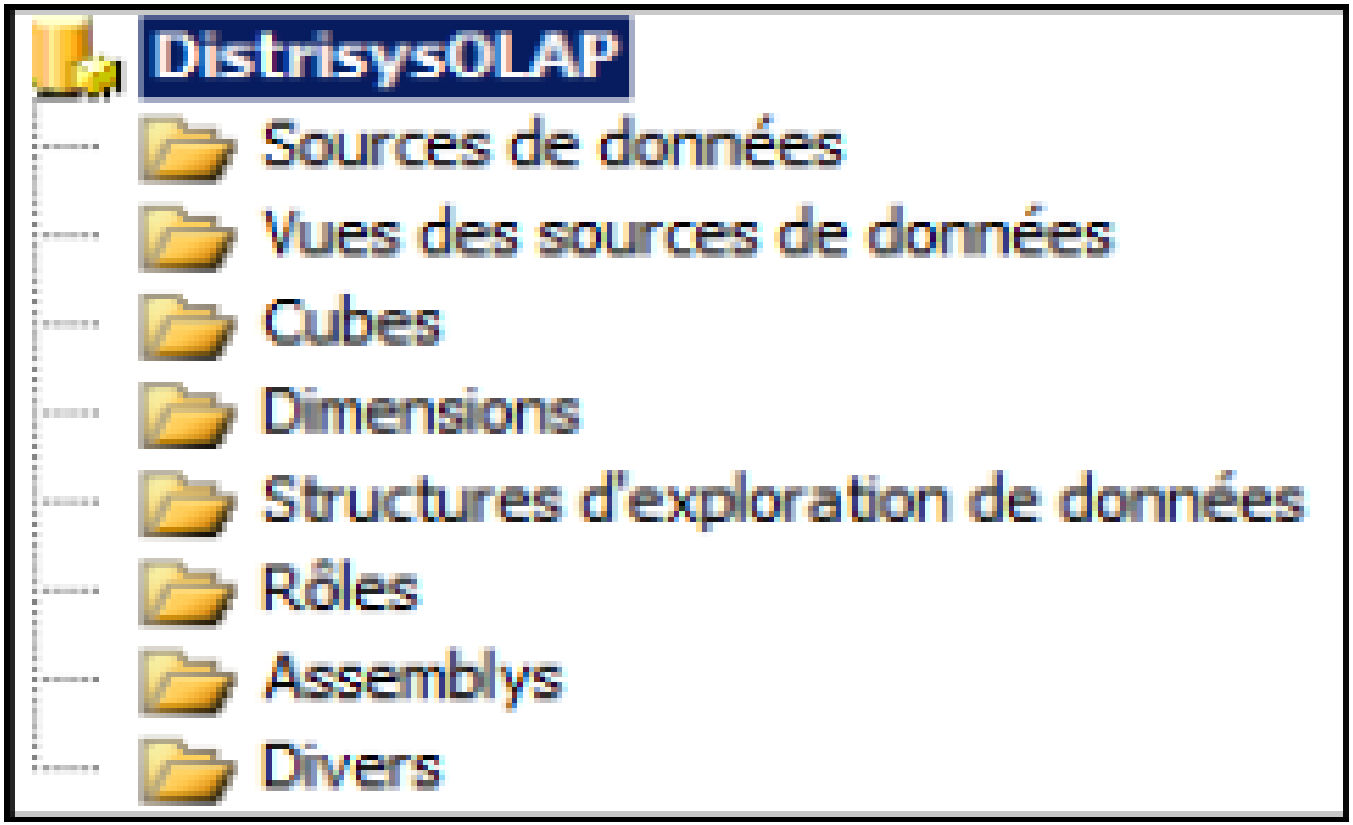

❑ OLAP SOUS SQL SERVER

❑ Cube avec SQL SERVER

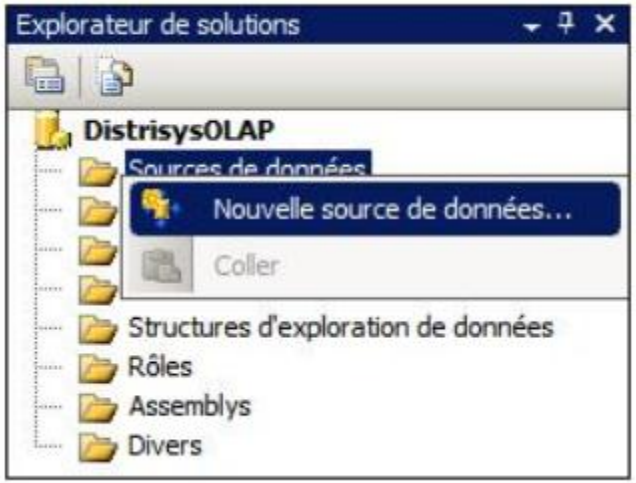

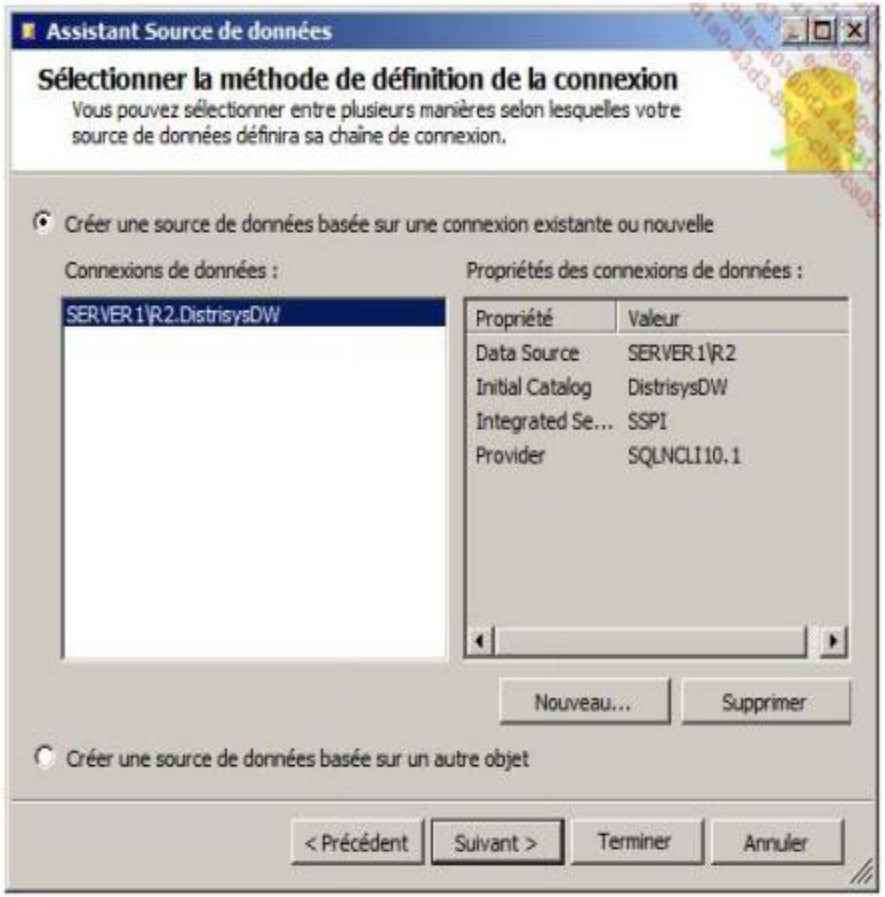

❑ OLAP SOUS SQL SERVER

❑ Cube avec SQL SERVER

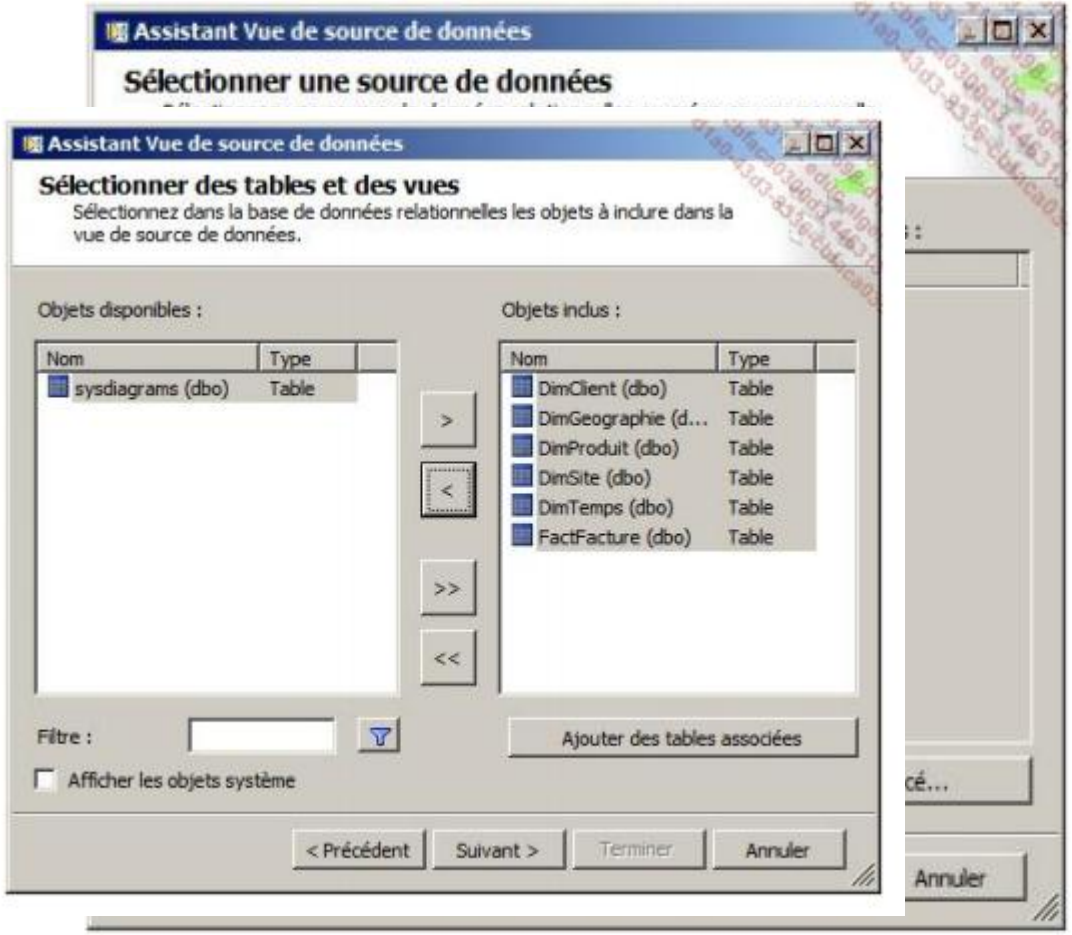

❑ OLAP SOUS SQL SERVER

❑ Cube avec SQL SERVER

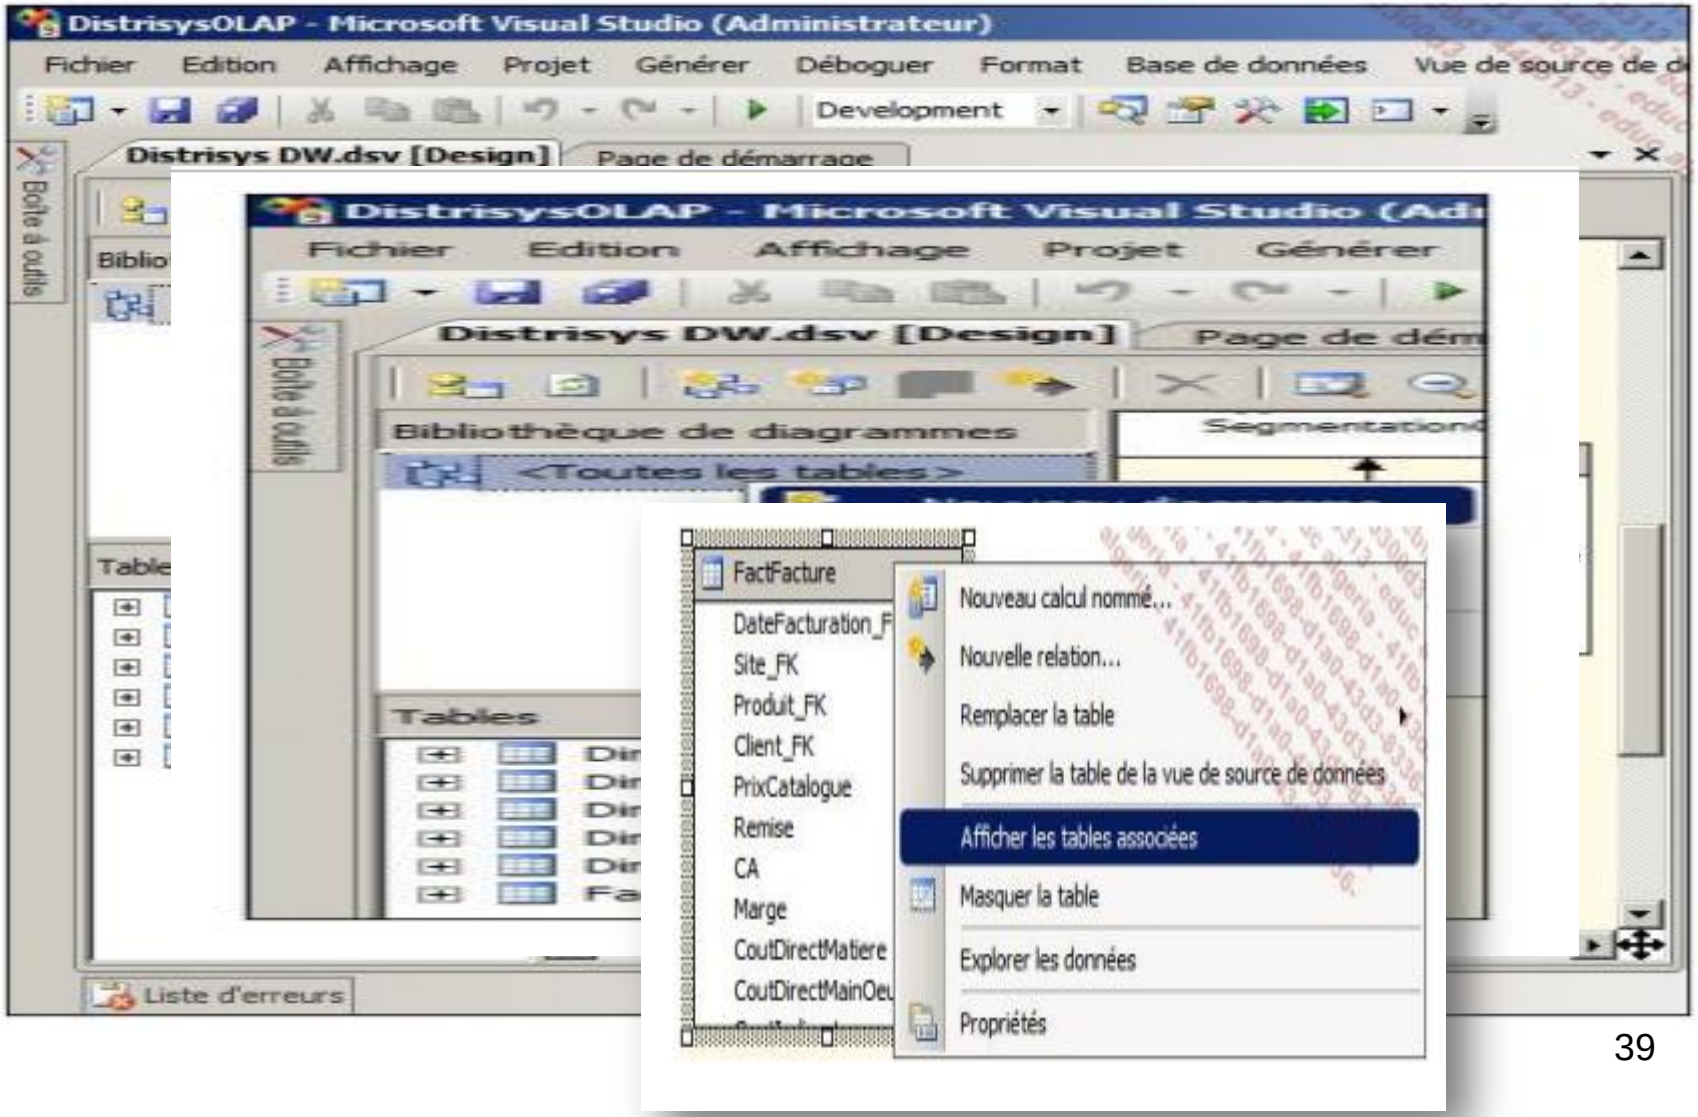

❑ OLAP SOUS SQL SERVER

❑ Cube avec SQL SERVER

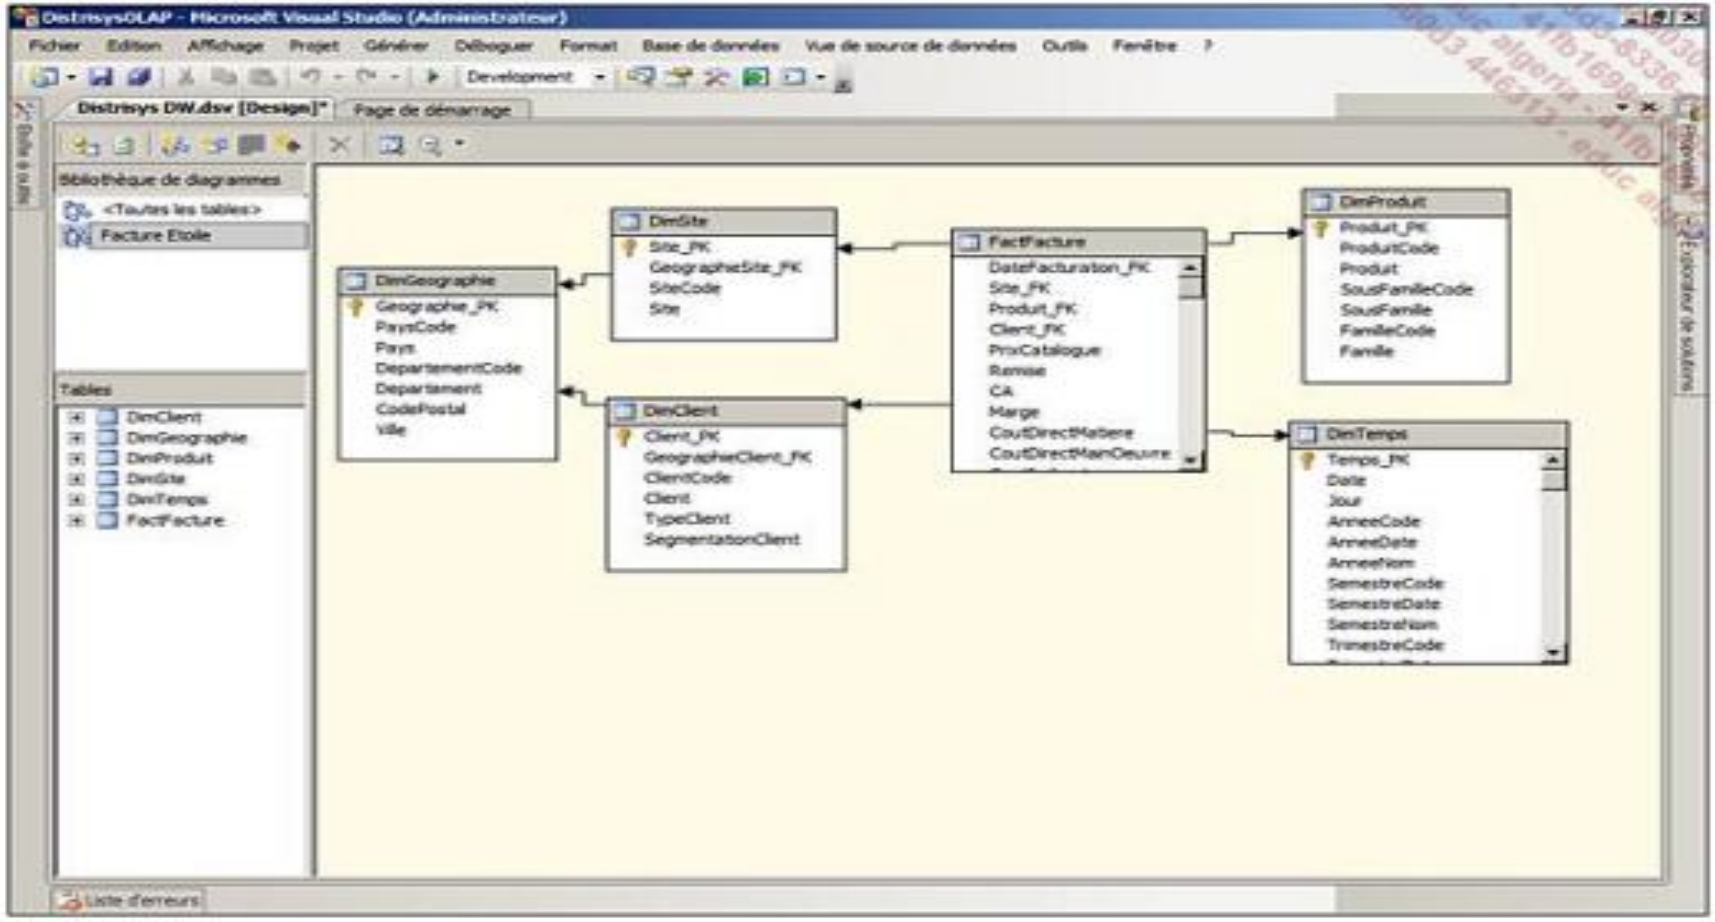

❑ OLAP SOUS SQL SERVER

❑ Cube avec SQL SERVER

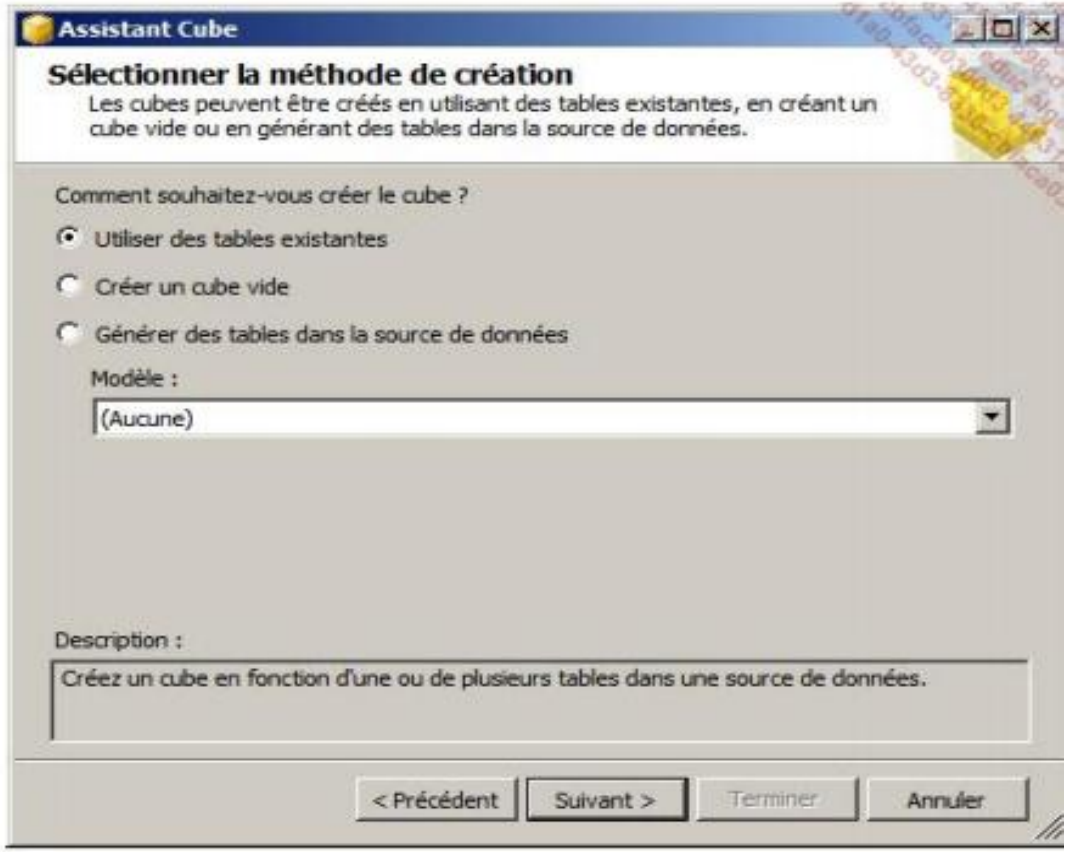

❑ OLAP SOUS SQL SERVER

❑ Cube avec SQL SERVER

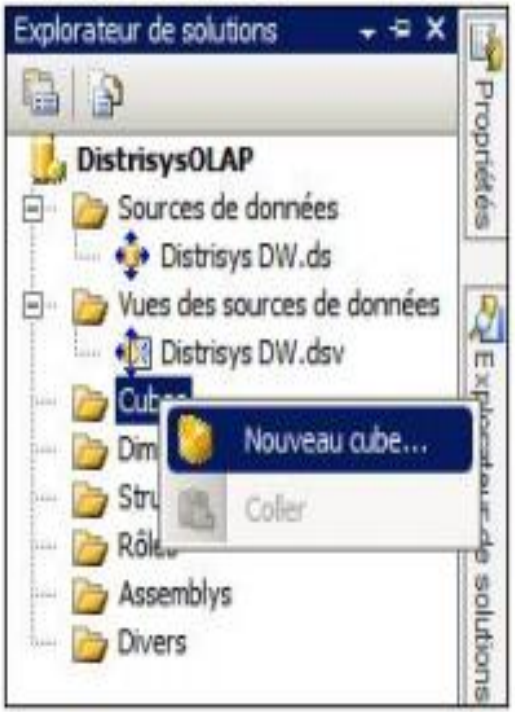

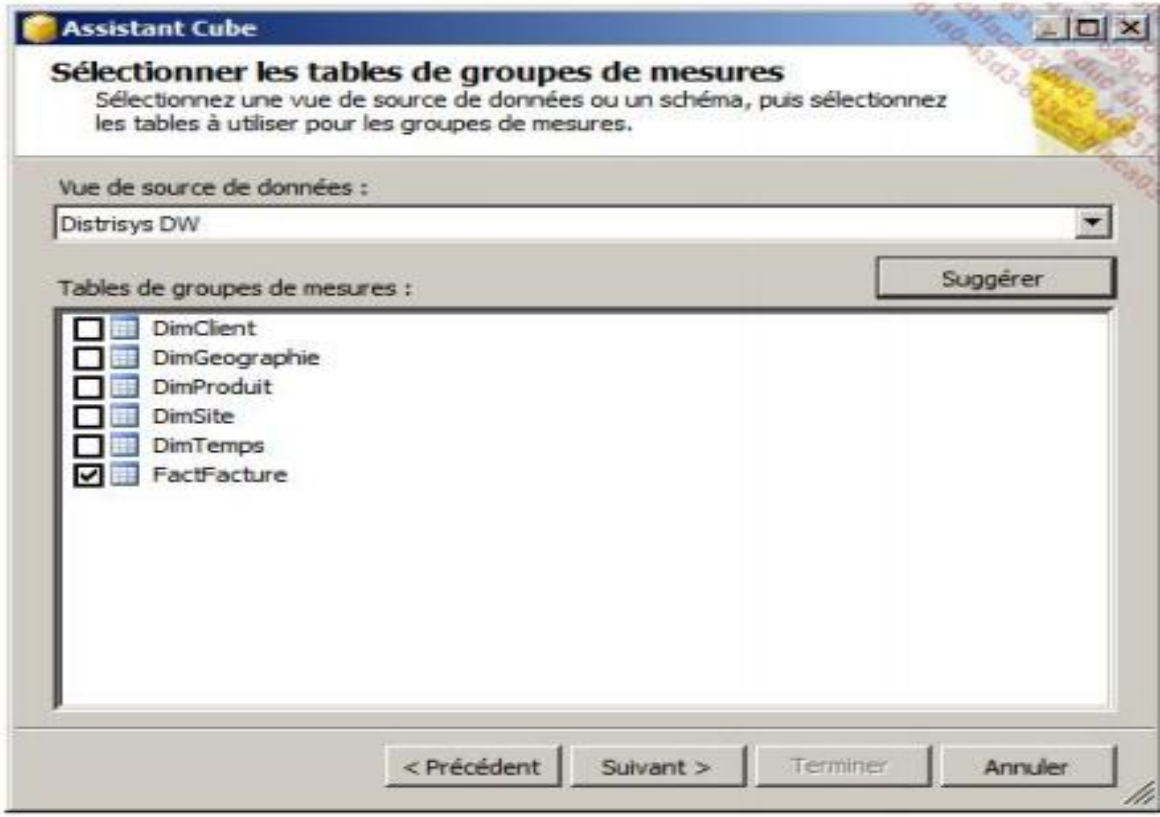

❑ Renommez le groupe de mesure **Fact Facture en Facture.**

❑ **Renommez les dimensions** pour les rendre plus compréhensibles à un non informaticien.

❑ OLAP SOUS SQL SERVER

❑ Cube avec SQL SERVER

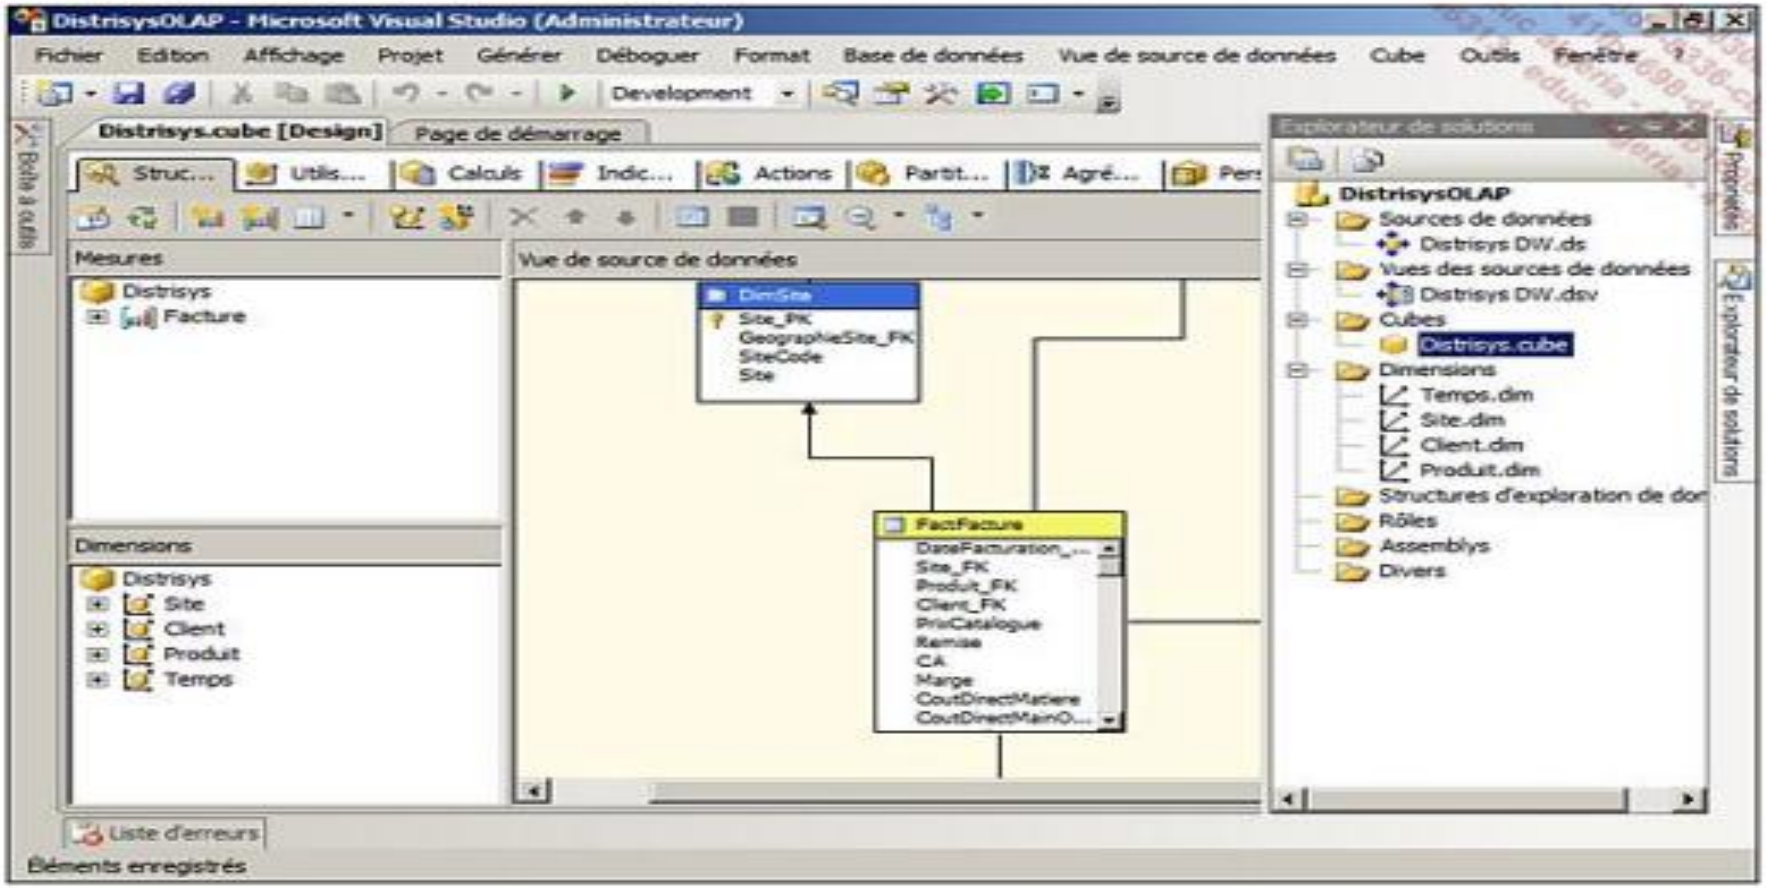

❑ OLAP SOUS SQL SERVER

❑ Cube avec SQL SERVER

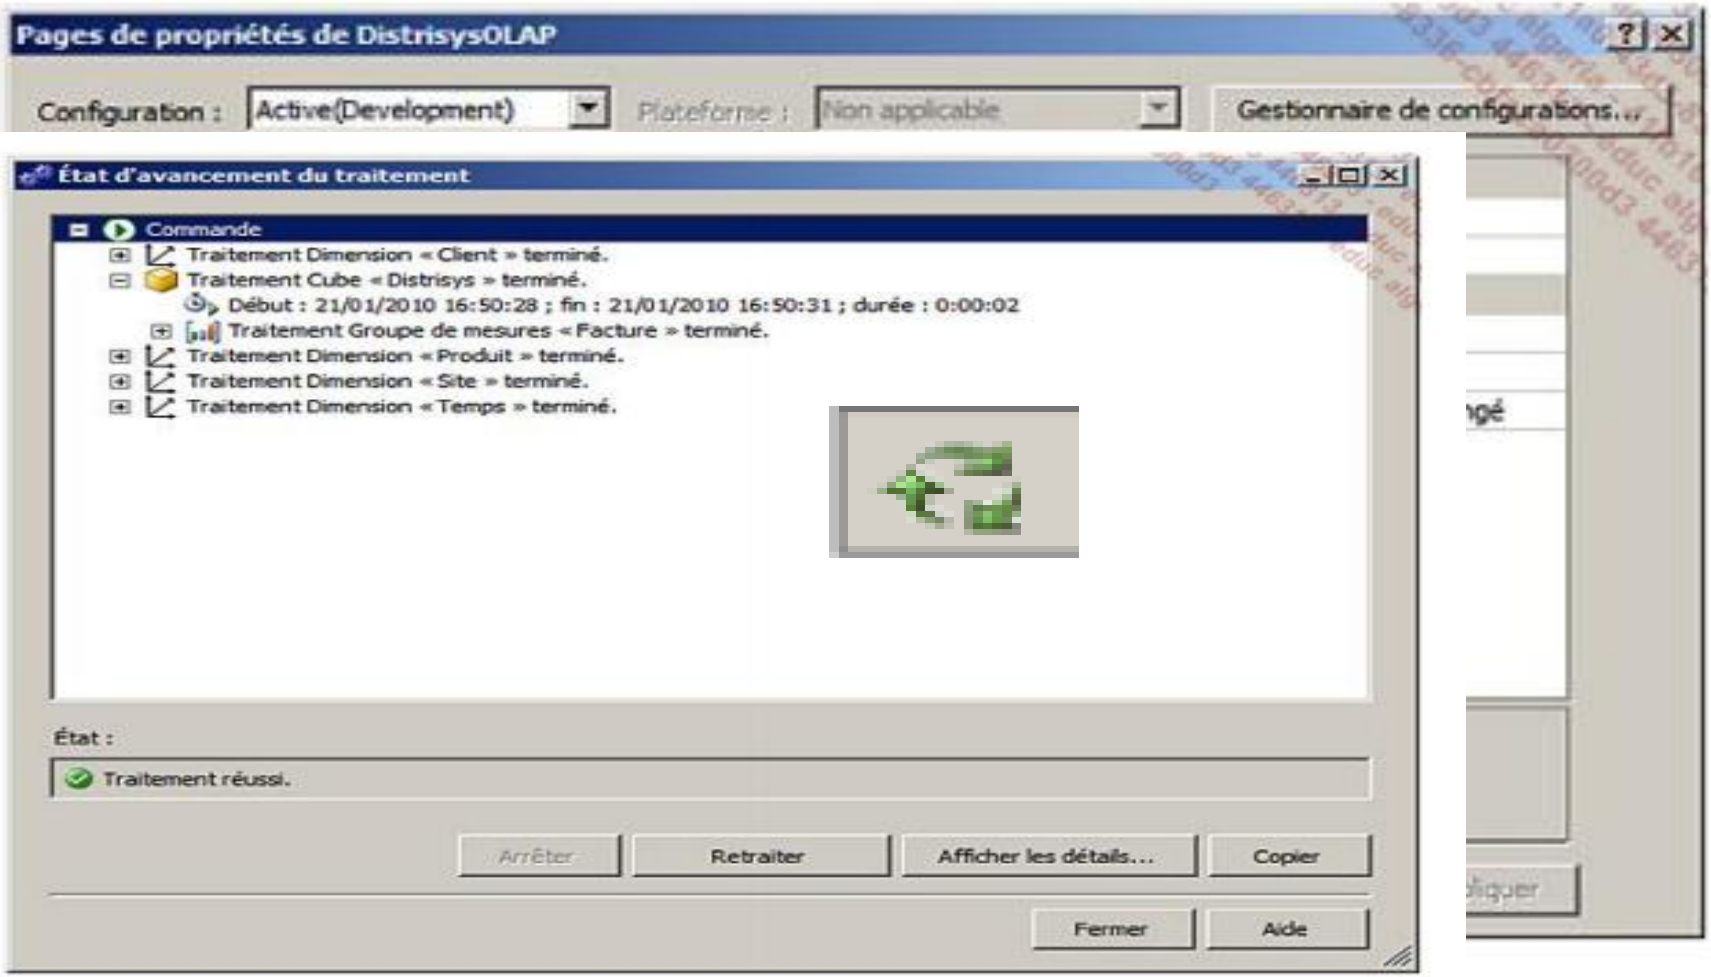

❑ OLAP SOUS SQL SERVER

❑ Cube avec SQL SERVER

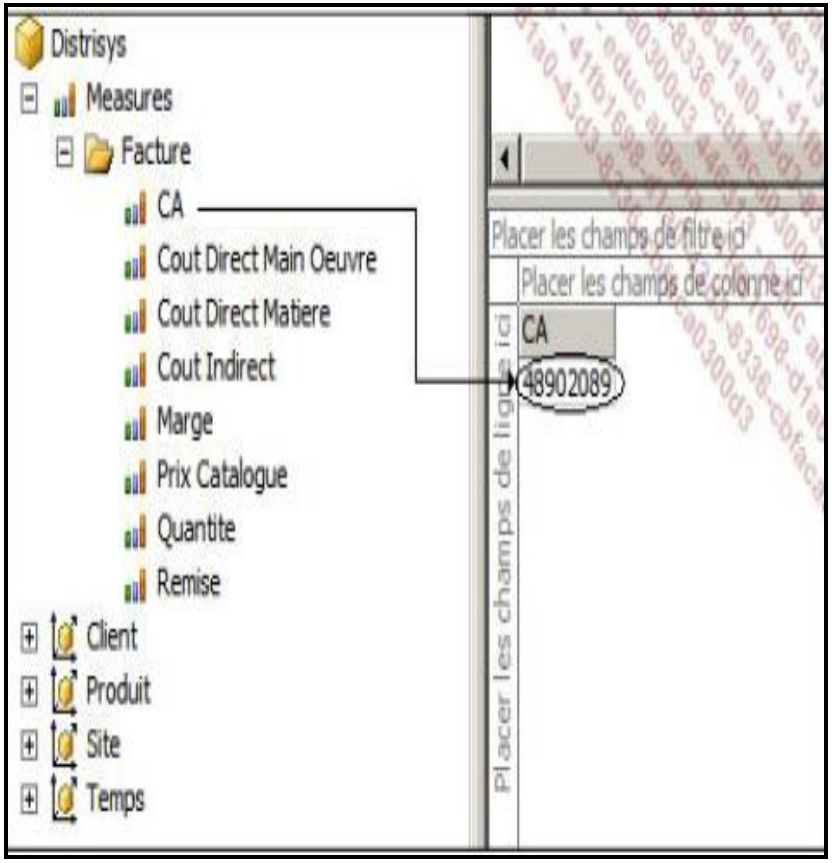

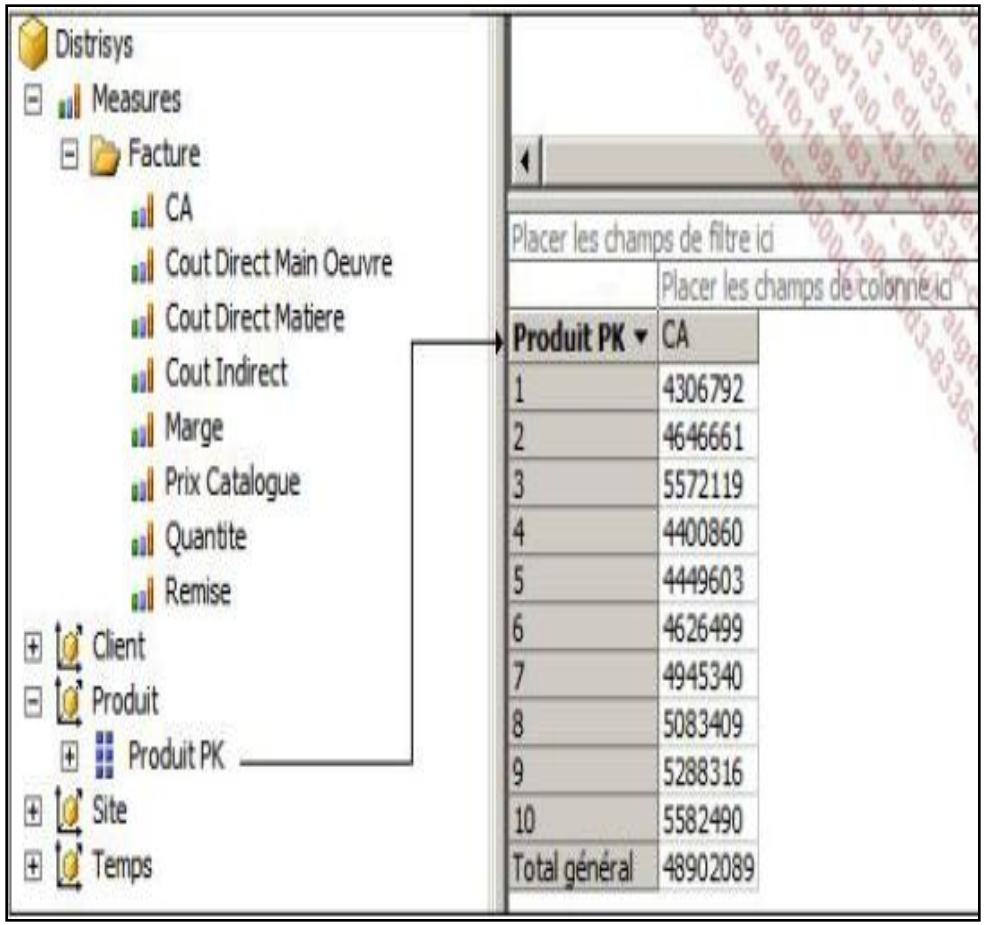

❑ OLAP SOUS SQL SERVER

❑ Cube avec SQL SERVER

Groupe de mesures :

<Tout>

- Distrisys
  - Measures
    - Facture
      - CA
      - Cout Direct Main Oeuvre
      - Cout Direct Matiere
      - Cout Indirect
      - Marge
      - Prix Catalogue
      - Quantite
      - Remise
  - Client
    - Hierarchie Segmentation
    - Hierarchie Topologie
    - Localisation Client
  - Produit
    - Famille - SousFamille - Produit
  - Site
    - Pays - Site

Dimension	Hiérarchie	Opérateur
<Sélectionnez une di...		

Pays - Site	Hierarchie Segmentation	Hierarchie Topologie
Siège social	Très Bon Client	Grande surface

	Annee					
	Calendrier 2009		Calendrier 2010		Total général	
Famille	CA	Quantite	CA	Quantite	CA	Quantite
Gros Menager	461747	1100	406517	935	868264	2035
Petit Menager	190201	611	314954	580	505155	1191
Total général	651948	1711	721471	1515	1373419	3226

Modèle propre et parfaitement manipulable par les utilisateurs

FIN